Previsão de demanda e otimização de estoque: por que este problema importa

Resumo. *Este primeiro artigo abre a série com o problema de negócio que vai sustentar todos os experimentos seguintes: previsão de demanda para reposição de estoque. O objetivo é mostrar por que esse problema é valioso, por que ele é difícil e por que ele cria um caminho didático natural até Reservoir Computing (RC) e Quantum Reservoir Computing (QRC). Em vez de começar pela teoria do reservatório, começamos pelo custo do erro no varejo, formalizamos a tarefa de previsão, fixamos o recorte experimental no dataset Favorita e mostramos as primeiras estatísticas reais da série* `store_nbr = 1` *e* `family = BEVERAGES`*. Ao final, o leitor sabe como carregar o recorte, entende as métricas que vão guiar a série, enxerga o impacto de promoção e calendário e tem um mapa completo dos sete artigos.*

0.1. 1. O que o leitor vai aprender

Ao final deste artigo, você será capaz de:

1. explicar por que previsão de demanda e um problema central de negócio;
2. formular matematicamente a tarefa de previsão da série;
3. reproduzir o recorte adotado no Favorita em toda a obra;
4. interpretar os primeiros artefatos computacionais antes de treinar qualquer modelo;
5. entender por que esse problema é uma boa rota pedagógica até QRC.

0.2. 2. O problema de negócio antes do modelo

Previsão de demanda é importante porque o erro entra diretamente na decisão de estoque. Se a empresa compra menos do que deveria, perde venda. Se compra mais, imobiliza capital e aumenta o risco de desperdício. Em um ambiente de varejo alimentar, isso acontece em escala diária, com milhares de decisões pequenas produzindo efeitos acumulados grandes.

Um modo simples de formalizar esse efeito é escrever o erro de previsão como

$$e_{t+h} = y_{t+h} - \hat{y}_{t+h},$$

em que y_{t+h} é a demanda observada e $\hat{y}_{t+h}$ é a previsão produzida no tempo t para o horizonte h.

Esse erro alimenta uma política operacional mínima de reposição:

$$R_t = \hat{y}_{t+1} + SS_t,$$

em que R_t é a quantidade planejada para reposição e SS_t é um estoque de segurança. Mesmo sem modelar toda a política de inventário, a equação deixa claro o ponto principal: melhorar $\hat{y}_{t+1}$ melhora a qualidade da decisão.

0.3. 3. Da pergunta de negócio para a tarefa de previsão

Ao longo da série, vamos modelar a tarefa como

$$\hat{y}_{t+h} = f(y_{1:t}, x_{1:t+h}),$$

em que:

- $y_{1:t}$ representa o histórico de vendas observado até o tempo t;
- $x_{1:t+h}$ representa sinais exógenos, como promoção e calendário;
- $f(\cdot)$ será implementada por modelos estatísticos, de IA clássica, RC e QRC.

Essa forma é importante pedagogicamente porque nos permite manter o mesmo problema enquanto trocamos a família de modelo. O que muda do artigo 1 ao 7 não é a pergunta. O que muda e a maneira de construir a representação temporal.

0.4. 4. O dataset Favorita e o recorte didático da série

O projeto usa o dataset da competição *Corporacion Favorita Grocery Sales Forecasting* como fio condutor. Para manter o ensino progressivo e reproduzível, toda a série começa no mesmo recorte:

- loja: `store_nbr = 1`
- família: `BEVERAGES`
- frequência: diária
- teste: últimos `90` dias

A tabela abaixo resume o recorte real usado nas implementações.

Métrica	Valor
Dias totais no recorte	1688
Dias de treino	1598
Dias de teste	90
Média diária de vendas	1583.99
Desvio padrão das vendas	729.89
Taxa média de promoção	60.37%
Taxa de dias com venda zero	0.59%
Inicio do treino	2013-01-01
Inicio do teste	2017-05-18
Fim do teste	2017-08-15

O carregamento desse recorte e implementado em `code/common/favorita.py`. O núcleo da reprodução e o seguinte:

```
from common.favorita import (
    FavoritaSeriesConfig,
    load_store_family_series,
    temporal_train_test_split,
)

config = FavoritaSeriesConfig(store_nbr=1, family="BEVERAGES",
test_days=90)
frame = load_store_family_series(store_nbr=config.store_nbr,
family=config.family)
train, test = temporal_train_test_split(frame,
test_days=config.test_days)
```

Esse código faz três coisas que sao centrais para toda a série:

1. fixa um recorte comum para todos os modelos;
2. densifica o calendário diário, preenchendo dias faltantes com zero;
3. garante um split temporal idêntico para comparações posteriores.

0.5. 5. O que os dados já ensinam antes de qualquer modelo

Antes de falar de RC ou QRC, vale observar o comportamento bruto da série.

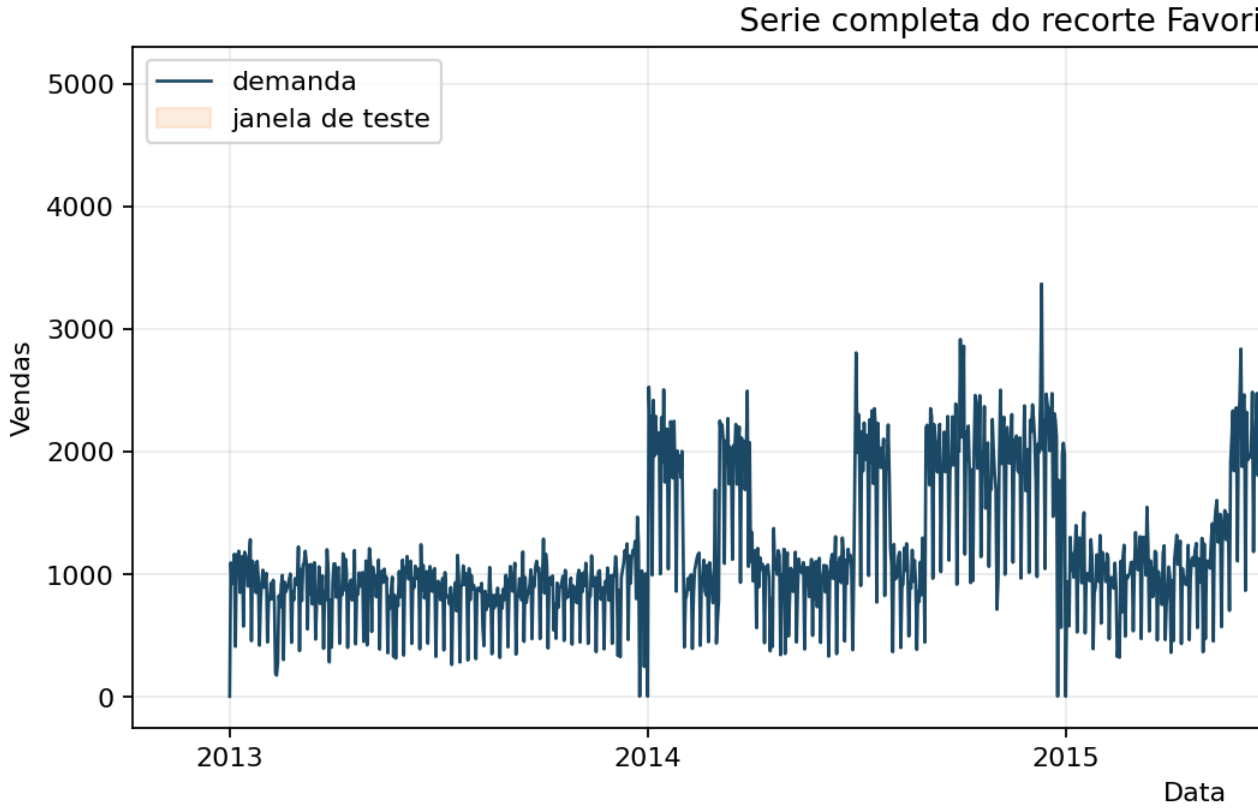

A visão geral mostra que o problema não é trivial por pelo menos três motivos:

- há variação forte ao longo do tempo;
- a série responde a padrões semanais;
- promoção altera o patamar das vendas.

O perfil semanal médio confirma esse último ponto.

Dia da semana	Média com promoção	Média sem promoção
Monday	2074.45	1125.28
Tuesday	2016.35	1046.04
Wednesday	2248.32	1166.31
Thursday	1927.36	1074.45
Friday	2116.13	1133.84
Saturday	2209.90	1232.53
Sunday	977.32	498.80

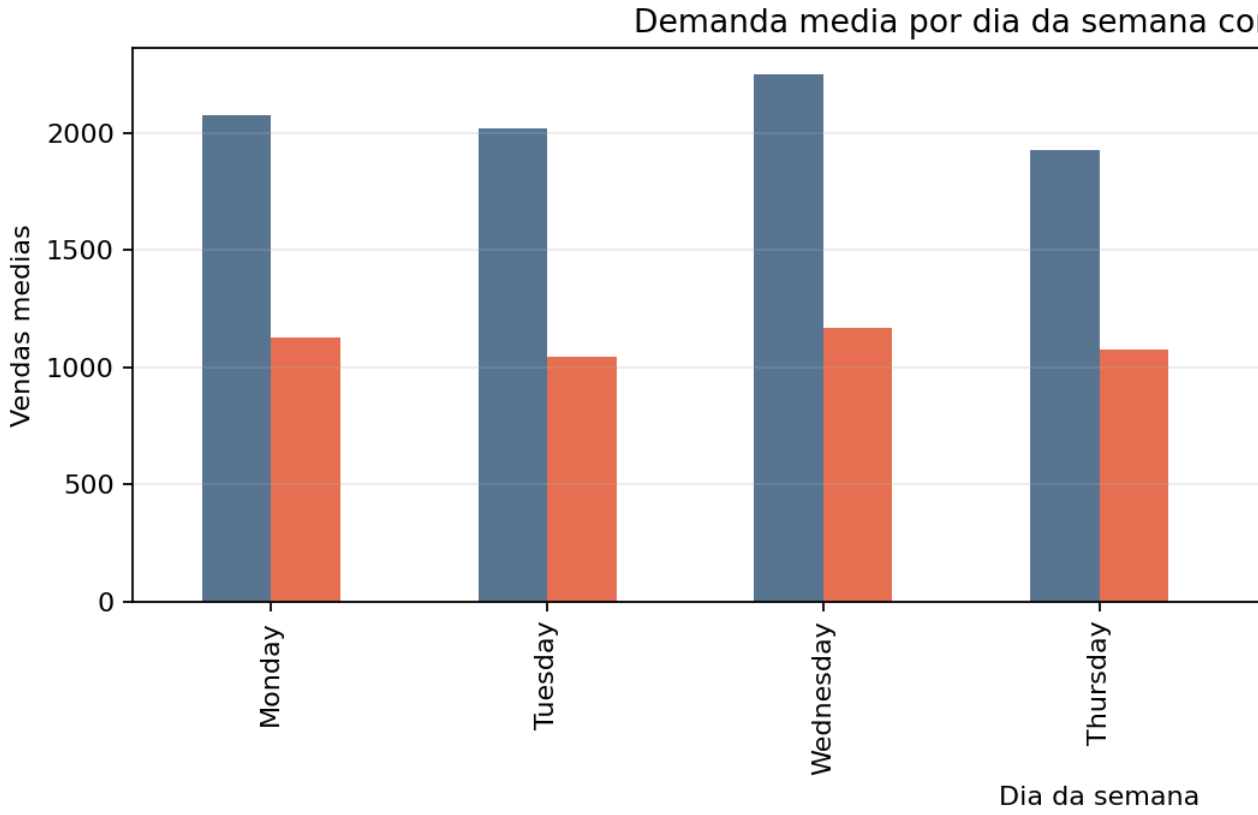

Duas leituras didáticas aparecem imediatamente:

1. a série tem sazonalidade semanal clara, o que justifica baselines como `Seasonal Naive` e `ETS`;
2. promoção desloca a média de vendas em todos os dias da semana, o que torna natural incluir variáveis exógenas.

Esse é o primeiro motivo para escolher esse problema como rota até QRC: mesmo o recorte inicial já exige memória temporal e sensibilidade a contexto.

0.6. 6. Passo-a-passo para reproduzir o recorte

O leitor pode reproduzir o ponto de partida da obra em quatro passos.

0.6.1. 6.1 Passo 1: localizar os dados

Os arquivos brutos foram organizados em `dataset/raw/`, com `train.csv`, `transactions.csv`, `stores.csv`, `holidays_events.csv`, `oil.csv` e `test.csv`.

0.6.2. 6.2 Passo 2: carregar uma única série

A função `load_store_family_series()` filtra por loja e família, ordena por data e produz um `DataFrame` com as colunas:

- `ds`: data
- `y`: demanda diária
- `onpromotion`: sinal exógeno básico usado nos modelos

0.6.3. 6.3 Passo 3: fixar o split temporal

A função `temporal_train_test_split()` implementa a regra que vamos herdar em toda a série:

- o passado vai para treino;
- os últimos `90` dias vão para teste;
- nenhuma observação do futuro entra no treino.

0.6.4. 6.4 Passo 4: inspecionar o recorte

Os artefatos computacionais deste artigo já mostram o mínimo necessario para não modelar no escuro:

- `series_overview.png`
- `weekly_profile.png`
- `recorte_summary.csv`

Em um projeto real, essa etapa não é opcional. Ela evita treinar modelos sofisticados sobre uma série mal definida.

0.7. 7. Como vamos medir desempenho

Toda a obra usa as mesmas quatro métricas, implementadas em `code/common/metrics.py`.

O erro absoluto médio e dado por

$$\mathrm{MAE} = \frac{1}{n} \sum_{t=1}^{n} |y_t - \hat{y}_t|.$$

O erro quadrático médio com raiz e dado por

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{t=1}^{n}(y_t - \hat{y}_t)^2}.$$

O erro absoluto ponderado pelo volume da série e dado por

$$\mathrm{WAPE} = \frac{\sum_{t=1}^{n}|y_t - \hat{y}_t|}{\sum_{t=1}^{n}|y_t|}.$$

E o erro percentual absoluto médio simetrico e dado por

$$\mathrm{sMAPE} = \frac{1}{n}\sum_{t=1}^{n}\frac{2|y_t - \hat{y}_t|}{|y_t| + |\hat{y}_t|}.$$

Essas métricas vão aparecer repetidamente porque cada uma responde a uma pergunta diferente:

- `MAE`: erro médio em unidades de venda;
- `RMSE`: sensibilidade a erros grandes;
- `WAPE`: erro relativo ao volume total;
- `sMAPE`: comparação percentual mais estável em séries com escalas diferentes.

0.8. 8. Por que esse problema conduz naturalmente até RC e QRC

Há pelo menos quatro motivos.

1. A série depende do passado, entao memória importa.
2. O efeito de promoção e calendário não é constante, entao não linearidade importa.
3. O protocolo de negócio e simples de explicar, entao o leitor não se perde no dominio.
4. O mesmo recorte pode ser usado para modelos estatísticos, IA clássica, RC e QRC.

Em outras palavras, o problema e suficientemente real para ser relevante e suficientemente controlado para ser didático.

0.9. 9. Roadmap dos sete artigos

O percurso da série será o seguinte:

1. artigo 1: problema de negócio, recorte e métricas;
2. artigo 2: fundamentos de Reservoir Computing;
3. artigo 3: primeiro pipeline reproduzível com baseline e RC;
4. artigo 4: memória, não linearidade e tuning do RC;
5. artigo 5: benchmark justo entre todas as implementações;
6. artigo 6: ponte de RC clássico para QRC;
7. artigo 7: estudo final de QRC no Favorita.

Essa organização evita um erro comum em textos de QRC: apresentar o formalismo quântico antes de o leitor entender a tarefa, o protocolo experimental e a lógica do reservatório.

0.10. 10. Conclusão

O ponto de partida da série esta estabelecido. Temos um problema de negócio real, um recorte experimental fixo, um pipeline mínimo de carregamento de dados e um conjunto de métricas que permitira comparações honestas. Esse chao comum e o que torna possível ensinar RC e QRC sem perder o leitor em abstrações.

O próximo artigo parte daqui para responder a pergunta central que o leitor provavelmente já esta fazendo: afinal, o que é um reservatório e por que ele pode ser útil para uma série temporal como essa?

0.11. Entregaveis associados no repositorio

- dados brutos: `dataset/raw/`
- carga do recorte: `code/common/favorita.py`
- métricas: `code/common/metrics.py`
- artefatos deste artigo: `computational_results_20260402_222902/`
- figuras principais: `series_overview.png` e `weekly_profile.png`

0.12. Referencias

- Corporacion Favorita Grocery Sales Forecasting. Kaggle.
- Hyndman, R. J.; Athanasopoulos, G. Forecasting: Principles and Practice.
- Jaeger, H. The "echo state"approach to analysing and training recurrent neural networks.
- Lukosevicius, M.; Jaeger, H. Reservoir computing approaches to recurrent neural network training.