# Fundamentos de Reservoir Computing

**Anderson Fernandes Pereira dos Santos**

Instituto Militar de Engenharia (IME), Rio de Janeiro, Brazil
Venturus Innovation Center, Campinas, Brazil
anderson@ime.eb.br | anderson.santos@venturus.org.br

***Resumo.*** *Este artigo apresenta Reservoir Computing (RC) como o primeiro grande degrau teórico da série. O foco não é apenas definir o termo, mas mostrar como um reservatório transforma uma sequência de entradas em uma representação dinâmica rica e por que isso e útil em previsão temporal. Partimos da intuição de memória distribuída, formalizamos o modelo mínimo com equações, conectamos cada elemento do formalismo a arquivos reais do projeto e mostramos artefatos computacionais intermediários do caso Favorita. Ao final, o leitor consegue ler o código do RC clássico do projeto, entende o papel do* `washout`*, sabe o que é treinado e o que não é treinado e fica preparado para executar o primeiro pipeline completo no artigo seguinte.*

## 1. O que o leitor vai aprender

Ao final deste artigo, você será capaz de:

1. definir um reservatório clássico de forma matemática;
2. distinguir estado interno, vetor de entrada e readout;
3. explicar o papel de `spectral_radius`, `leak_rate` e `washout`;
4. mapear as equações de RC para a implementação em `code/rc/model.py`;
5. interpretar artefatos intermediários, e não apenas métricas finais.

## 2. A intuição: um reservatório e uma memória dinâmica

Em um modelo tabular tradicional, as features costumam ser calculadas explicitamente: lags, médias moveis, indicadores de calendário e assim por diante. Em RC, a ideia e diferente. Em vez de escrever manualmente toda a representação temporal, injetamos a sequência em um sistema dinamico recorrente e usamos seus estados internos como uma base de representação.

A intuição mais útil para iniciantes e esta:

- a entrada $u_t$ perturba o sistema;
- o estado $x_t$ carrega um resumo dinamico do passado recente;
- o readout linear aprende a converter esse resumo em previsão.

RC é atraente didaticamente porque separa o problema em duas partes:

1. um mecanismo fixo de representação temporal;
2. uma camada simples de regressão treinável.

## 3. Construindo o modelo mínimo de RC

Em muitos textos de RC, a equação do reservatório aparece pronta, em uma única linha. Para quem está vendo o tema pela primeira vez, isso costuma ser brusco demais. Aqui vamos fazer o caminho inverso: primeiro identificamos os ingredientes da atualização, depois construímos o estado candidato, e só ao final escrevemos a equação completa.

### 3.1. Os ingredientes da atualização

Em cada instante $t$, o reservatório recebe uma entrada $u_t$ e mantém internamente um estado $x_{t-1}$ vindo do passo anterior. O objetivo da atualização é responder à pergunta:

> dado o que entrou agora e dado o que o sistema ainda "lembra"do passado,
> qual deve ser o novo estado interno?

Para responder a essa pergunta, o modelo usa:

- $u_t \in \mathbb{R}^d$, o vetor de entrada no tempo $t$;
- $x_{t-1} \in \mathbb{R}^N$, o estado interno do passo anterior;
- $W_{in}$, a matriz que projeta a entrada para o espaço do reservatório;
- $W_{res}$, a matriz recorrente interna, que mistura os componentes do próprio estado;
- $b$, um vetor de bias;
- $\alpha \in (0, 1]$, o `leak_rate`, que controlará quanto do estado novo realmente entra.

Antes de pensar em "novo estado", vale notar que o reservatório olha para duas fontes de informação ao mesmo tempo:

1. a entrada atual, que chega por $W_{in}u_t$;
2. a memória interna, que chega por $W_{res}x_{t-1}$.

### 3.2. Primeiro passo: combinar passado e entrada

O primeiro passo é formar uma ativação bruta, que ainda não é o novo estado final. Chamaremos essa quantidade de pré-ativação:

$$z_t = W_{res}x_{t-1} + W_{in}u_t + b.$$

Essa expressão deve ser lida com calma:

- $W_{res}x_{t-1}$ leva a informação do passado para o presente;
- $W_{in}u_t$ injeta a entrada atual no reservatório;
- $b$ desloca a resposta de cada unidade.

O vetor $z_t$ representa, portanto, a resposta linear bruta do sistema antes de qualquer limitação ou filtragem.

### 3.3. Segundo passo: obter o estado candidato

Se usássemos diretamente $z_t$ como novo estado, o modelo permaneceria linear demais e os valores internos poderiam crescer sem controle. Por isso, aplicamos uma não linearidade componente a componente:

$$\widetilde{x}_t = \tanh(z_t).$$

Substituindo $z_t$, obtemos:

$$\widetilde{x}_t = \tanh(W_{res}x_{t-1} + W_{in}u_t + b).$$

O vetor $\widetilde{x}_t$ é chamado aqui de **estado candidato**. Ele representa a resposta que o reservatório produziria se reagisse imediatamente ao passo atual. A função $\tanh(\cdot)$ comprime os valores para o intervalo $(-1, 1)$, introduz não linearidade e ajuda a manter a dinâmica interna em uma faixa estável.

Em linguagem intuitiva:

- $z_t$ é a ativação bruta;
- $\widetilde{x}_t$ é a proposta de novo estado depois da filtragem não linear.

### 3.4. Terceiro passo: misturar memória e atualização nova

O reservatório ainda não adota $\widetilde{x}_t$ como estado final. Em vez disso, ele mistura parte da memória anterior com parte do estado candidato:

$$x_t = (1 - \alpha)x_{t-1} + \alpha\widetilde{x}_t.$$

Essa é uma equação importante pedagogicamente. Ela mostra que o reservatório não "apaga"o passado a cada passo. O parâmetro $\alpha$ controla a velocidade da atualização:

- se $\alpha$ é pequeno, o sistema preserva mais memória e muda devagar;
- se $\alpha$ é grande, o sistema reage mais ao presente e muda mais rápido.

### 3.5. A equação completa do reservatório

Agora sim podemos juntar os passos anteriores. Substituindo o estado candidato na equação de mistura, chegamos à dinâmica completa:

$$x_t = (1 - \alpha)x_{t-1} + \alpha \tanh(W_{res}x_{t-1} + W_{in}u_t + b).$$

Nessa forma final:

- $u_t$ é a entrada atual;
- $x_{t-1}$ é a memória interna trazida do passo anterior;
- $W_{res}$ modela a recorrência interna do reservatório;
- $W_{in}$ projeta a entrada para o espaço de estados;
- $b$ desloca a ativação;
- $\alpha$ controla o equilíbrio entre memória e atualização.

No código, essa construção aparece de forma quase literal em `EchoStateReservoir.step()`:

```
pre_activation = (
    self.recurrent_weights @ self.state
    + self.input_weights @ input_vector
    + self.bias
)
new_state = np.tanh(pre_activation)
self.state = (1.0 - self.config.leak_rate) * self.state + self.config.l
```

A correspondência entre teoria e implementação fica mais fácil de ler quando usamos os mesmos três passos:

1. `pre_activation` corresponde a $z_t$;
2. `new_state` corresponde a $\widetilde{x}_t$;
3. `self.state = ...` corresponde à atualização final de $x_t$.

### 3.6. Como a previsão sai do estado interno

A dinâmica do reservatório produz uma representação temporal, mas ainda não produz a previsão final. Para isso, usamos um readout linear:

$$\hat{y}_t = W_{out}\phi_t, \qquad \phi_t = [1; u_t; x_t].$$

O vetor $\phi_t$ concatena três elementos:

- um termo constante, representado por `1`;
- a entrada atual $u_t$;
- o estado interno $x_t$.

No projeto, `\phi_t` é construída por `_feature_vector()` e `W_out` é ajustado via regressão Ridge.

## 4. O que é treinado e o que não é treinado

Um dos pontos mais didáticos de RC e a divisão entre dinâmica fixa e leitura treinável.

No projeto:

- `W_in`, `W_res` e `b` sao inicializados aleatoriamente e mantidos fixos;
- apenas o readout linear e ajustado com supervisão.

Formalmente, o treinamento resolve

$$W_{out}^* = \arg\min_{W_{out}} \|Y - \Phi W_{out}\|_2^2 + \lambda \|W_{out}\|_2^2,$$

em que $\Phi$ é a matriz de features acumuladas ao longo do tempo e $\lambda$ é o hiperparametro de regularização Ridge.

Essa escolha reduz o custo de treinamento em relação a RNNs totalmente treináveis e, ao mesmo tempo, preserva uma representação temporal rica.

## 5. Como o tempo entra no modelo

No projeto, o vetor de entrada sequencial e construído em `code/common/sequential_features.py` com sete componentes:

- demanda prévia normalizada;
- promoção normalizada;
- `dow_sin`, `dow_cos`;
- `month_sin`, `month_cos`;
- indicador de fim de semana.

Em notação compacta,

$$u_t = \begin{bmatrix} \widetilde{y}_{t-1} & \widetilde{p}_t & \sin(2\pi\,\mathrm{dow}_t/7) & \cos(2\pi\,\mathrm{dow}_t/7) & \sin(2\pi\,\mathrm{month}_t/12) & \cos(2\pi\,\mathrm{month}_t/12) & \mathbb{1}_{\mathrm{weekend}} \end{bmatrix}^\top$$

Esse vetor coloca em uma mesma representação:

- memória de curtissimo prazo, via $\widetilde{y}_{t-1}$;
- contexto exógeno, via promoção;
- ciclo temporal, via senos e cossenos.

## 6. O papel do washout

Nos primeiros instantes da simulação, o estado do reservatório ainda esta fortemente contaminado pela inicialização. Por isso, o projeto descarta os primeiros passos antes de treinar o readout.

Se chamarmos o `washout` de $w$, o treino do readout usa apenas os tempos $t \geq w$:

$$\Phi = [\phi_w, \phi_{w+1}, \ldots, \phi_T]^\top.$$

Em `fit_rc_readout()`, isso aparece no teste `if idx >= config.washout`.

O `washout` não é um detalhe de implementação. Ele e uma parte conceitual do pipeline, porque separa a transiente inicial da dinâmica que realmente queremos aproveitar.

## 7. Como o projeto implementa RC no caso Favorita

A tabela abaixo resume o pipeline implementado.

| Objeto | Dimensão no projeto | Origem |
|---|---|---|
| Vetor de entrada $u_t$ | 7 | `scaled_input_vector()` |
| Estado do reservatório $x_t$ | 80 | `RCConfig.n_reservoir` |
| Vetor de features $[1; u_t; x_t]$ | 88 | `_feature_vector()` |
| Readout | 1 saida | Ridge linear sobre as features |

O fluxo completo do código e o seguinte:

1. `build_scaler_state()` calcula médias e desvios para normalizacao;
2. `scaled_input_vector()` constroi $u_t$;
3. `EchoStateReservoir.step()` atualiza $x_t$;
4. `_feature_vector()` monta $\phi_t = [1; u_t; x_t]$;
5. `Ridge.fit()` estima o readout;
6. `forecast_rc()` faz previsão recursiva no bloco de teste.

O trecho central do treinamento e este:

```
input_vector = scaled_input_vector(prev_y, row, scaler=scaler)
state = reservoir.step(input_vector)
feature_rows.append(_feature_vector(state, input_vector))
targets.append(float(row["y"]))
```

Isso mostra a ideia central de RC em sua forma mais simples: o modelo não aprende uma representação temporal diretamente por backpropagation; ele coleta estados dinamicos e aprende apenas como le-los.

## 8. O que os artefatos intermediários mostram

O artigo não precisa esperar a métrica final para ensinar alguma coisa. Os artefatos computacionais deste modulo mostram o pipeline em um nivel mais interno.

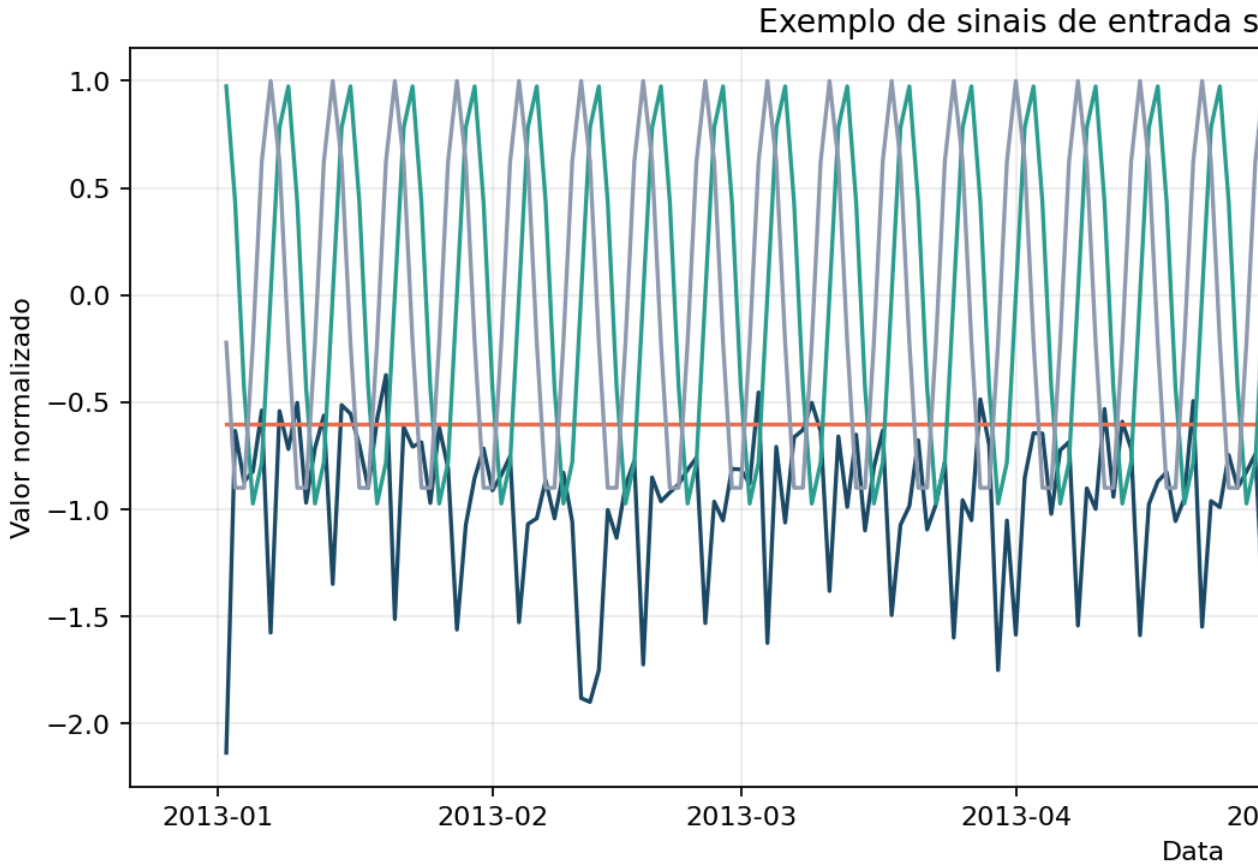


A imagem de entrada sequencial mostra que o reservatório não recebe apenas uma série de vendas crua. Ele recebe uma codificacao temporal e exógena compacta.

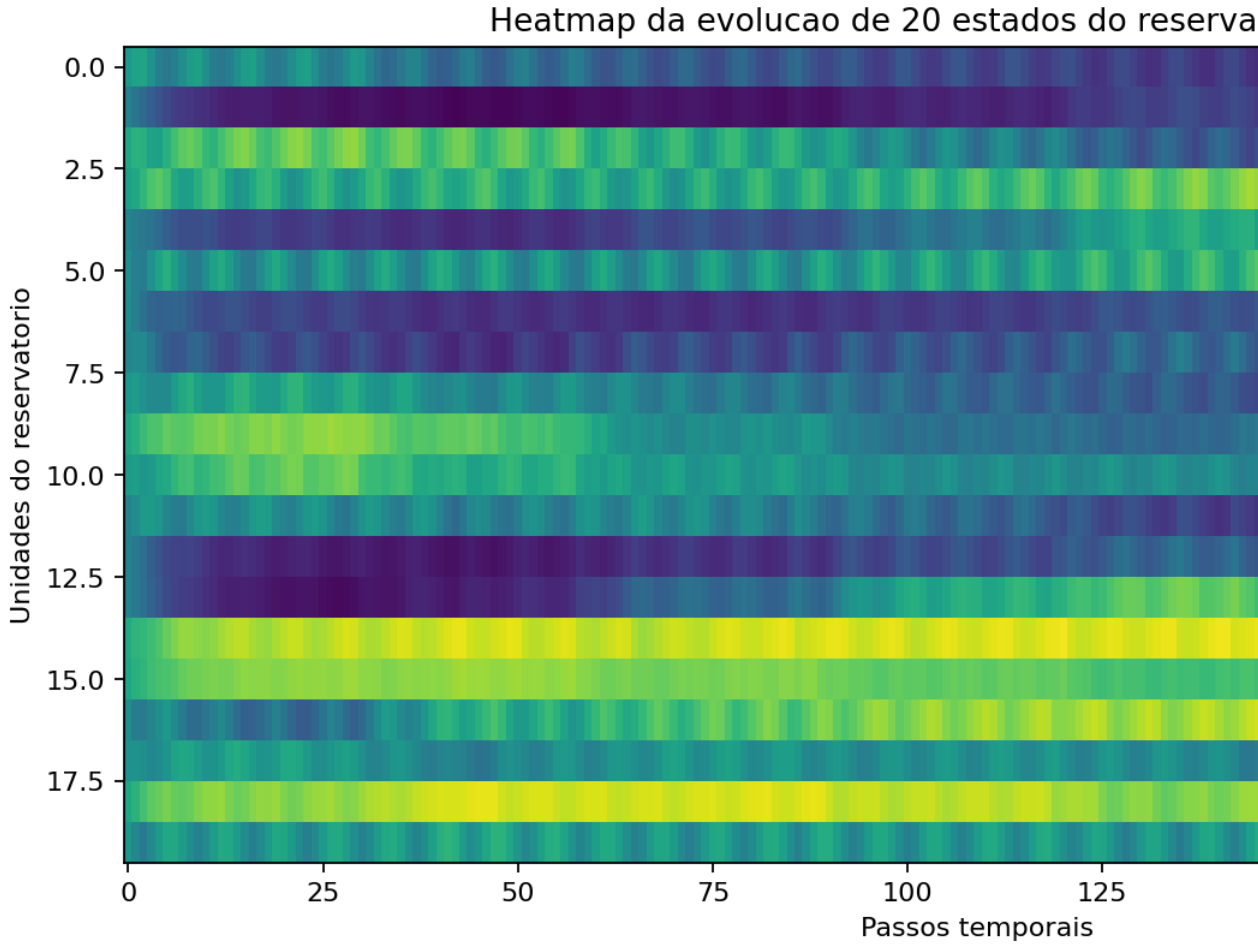


O heatmap dos estados ilustra duas ideias importantes:

1. unidades diferentes respondem de modos diferentes ao mesmo estimulo;
2. a memória do reservatório não é um unico lag explícito, mas uma combinacao distribuída de estados.

Em outras palavras, RC constroi uma base dinâmica de features sem precisar enumerar manualmente toda a interação temporal.

## 9. Comparando RC com outras famílias de modelo

Vale situar RC entre outros paradigmas que também aparecem na série:

- `Seasonal Naive`, `ETS` e `Prophet` modelam estrutura temporal de forma mais explícita;
- `XGBoost` usa engenharia de atributos tabulares;
- `LSTM` aprende dinâmica recorrente via gradiente;
- `RC` fixa a dinâmica recorrente e treina apenas o readout.

Essa posicao intermediária e pedagogicamente muito poderosa. RC é mais rico do que um baseline ingenuo, mas muito mais simples de treinar do que uma RNN completa.

## 10. Passo-a-passo para estudar ou modificar o RC do projeto

Um leitor que queira estudar a implementação deve seguir esta ordem:

1. abrir `code/common/sequential_features.py`;
2. verificar como o vetor `u_t` e construído;
3. abrir `code/rc/model.py` e localizar `RCConfig`;
4. ler `EchoStateReservoir.step()` junto da equação do artigo;
5. ler `fit_rc_readout()` e localizar o `washout`;
6. executar `python code/rc/run.py`;
7. validar o comportamento com `pytest code/rc/test_model.py`.

Essa ordem importa. Se o leitor abrir apenas `run.py`, perde a correspondencia entre teoria e implementação.

## 11. Conclusão

RC já esta completamente formulado no contexto do projeto. Temos uma definicao matemática, uma implementação concreta e artefatos intermediários que mostram a representação temporal em acao. O próximo passo natural e colocar esse modelo em confronto com um baseline forte, medindo o que ele realmente entrega no recorte adotado no Favorita.

### Entregaveis associados no repositorio

- implementação do RC: `code/rc/model.py`
- execucao do RC: `code/rc/run.py`
- testes do RC: `code/rc/test_model.py`
- construcao de entrada sequencial: `code/common/sequential_features.py`
- artefatos deste artigo: `computational_results_20260402_222902/`

## 12. Referências

### Referências


[1] JAEGER, H. **The "echo state" approach to analysing and training recurrent neural networks**. Bonn: German National Research Center for Information Technology (GMD), 2001.

[2] LUKOSEVICIUS, M.; JAEGER, H. **Reservoir computing approaches to recurrent neural network training**. *Computer Science Review*, v. 3, n. 3, p. 127–149, 2009.

[3] LUKOSEVICIUS, M. **A practical guide to applying echo state networks**. In: MONTAVON, G.; ORR, G. B.; MÜLLER, K.-R. (org.). *Neural Networks: Tricks of the Trade*. 2. ed. Berlin: Springer, 2012. p. 659–686.

[4] FUJII, K.; NAKAJIMA, K. **Harnessing disordered-ensemble quantum dynamics for machine learning**. *Physical Review Applied*, v. 8, n. 2, 024030, 2017.