Fundamentos de Reservoir Computing

Anderson Fernandes Pereira dos Santos

Instituto Militar de Engenharia (IME), Rio de Janeiro, Brazil
Venturus Innovation Center, Campinas, Brazil
anderson@ime.eb.br | anderson.santos@venturus.org.br

Resumo. *Este artigo apresenta Reservoir Computing (RC) como o primeiro grande degrau teórico da série. O foco não é apenas definir o termo, mas mostrar como um reservatório transforma uma sequência em uma representação dinâmica heterogenea, não linear e com memória distribuída. Além da intuição e das equações, o texto introduz uma camada que faltava na versão anterior: como avaliar o que o RC realmente entrega em três níveis diferentes: qualidade da representação interna, qualidade da previsão final e qualidade da estabilidade experimental. No recorte Favorita, o RC clássico funciona, produz estados coerentes e previsões reprodutíveis, mas a configuração default ainda fica atrás de* `Seasonal Naive` *e* `ETS`*. Também mostramos que seed,* `spectral_radius`*,* `leak_rate`*,* `washout` *e* `n_reservoir` *mudam materialmente o erro, o que transforma esses hiperparâmetros em decisões de projeto, e não em detalhes cosméticos.*

1. O que o leitor vai aprender

Ao final deste artigo, você será capaz de:

1. definir um reservatório clássico de forma matemática;
2. distinguir estado interno, vetor de entrada e readout;
3. explicar o papel de `spectral_radius`, `leak_rate` e `washout`;
4. mapear as equações de RC para a implementação em `code/rc/model.py`;
5. separar qualidade da representação interna, qualidade da previsão final e qualidade da estabilidade experimental.

2. A intuição: o que um reservatório faz, antes da equação

Em um modelo tabular tradicional, as features costumam ser calculadas explicitamente: lags, médias móveis, indicadores de calendário e assim por diante. Em RC, a ideia é diferente. Em vez de escrever manualmente toda a representação temporal, injetamos a sequência em um sistema dinamico recorrente e usamos seus estados internos como uma base de representação.

A melhor imagem mental para um iniciante é esta:

- a entrada u_t entra no sistema no instante atual;
- o sistema ainda guarda parte do que aconteceu antes;
- essa mistura entre presente e passado gera um novo estado interno;
- a previsão final e feita a partir desse estado.

Em outras palavras, o reservatório não tenta prever diretamente. Primeiro ele **transforma a sequência em estados internos**. Só depois o readout aprende a ler esses estados.

Se quisermos resumir RC em uma frase curta, ela seria:

> o reservatório e um mecanismo fixo que converte sequências em representações dinâmicas; o readout e a parte treinada que converte essas representações em previsão.

Essa divisão é importante porque reduz a carga conceitual:

1. primeiro entendemos como o estado interno evolui;
2. depois entendemos como a previsão sai desse estado.

3. Construindo o modelo mínimo de RC

Em muitos textos de RC, a equação do reservatório aparece pronta, em uma única linha. Para quem esta vendo o tema pela primeira vez, isso costuma ser brusco demais. Aqui vamos fazer o caminho inverso: começamos com a pergunta intuitiva, descemos até um único passo de atualizacao, olhamos um exemplo de uma única unidade e só entao escrevemos a equação completa.

3.1. A pergunta central em um único passo

Em cada instante t, o reservatório recebe uma entrada u_t e mantem internamente um estado x_{t-1} vindo do passo anterior. O problema do passo atual pode ser formulado assim:

> dado o que entrou agora e dado o que o sistema ainda guarda do passado, como produzir o novo estado x_t?

Essa pergunta já organiza quase todo o raciocinio. O novo estado precisa depender de duas coisas:

- da entrada atual;
- da memória que o proprio sistema traz do passo anterior.

3.2. Os ingredientes da atualizacao

Para responder a essa pergunta, o modelo usa:

- $u_t \in \mathbb{R}^d$, o vetor de entrada no tempo t;
- $x_{t-1} \in \mathbb{R}^N$, o estado interno do passo anterior;
- W_{in}, a matriz que projeta a entrada para o espaco do reservatório;
- W_{res}, a matriz recorrente interna, que mistura os componentes do proprio estado;
- b, um vetor de bias;
- $\alpha \in (0, 1]$, o `leak_rate`, que controlara quanto do estado novo realmente entra.

O ponto principal aqui não é decorar a notação. O ponto principal e perceber o papel de cada termo:

- $W_{in}u_t$ traz o **efeito da entrada atual**;
- $W_{res}x_{t-1}$ traz o **efeito do passado interno**;
- b apenas desloca essa resposta;
- α vai decidir quanto do estado novo substitui o antigo.

3.3. Primeiro passo: montar a resposta bruta do sistema

Antes de falar em "estado candidato", vale pensar no que acontece imediatamente quando somamos os efeitos do presente e do passado. Chamaremos essa soma de pre-ativacao:

$$z_t = W_{res}x_{t-1} + W_{in}u_t + b.$$

Essa expressão pode ser lida em voz alta assim:

resposta bruta no tempo t = efeito da memória anterior + efeito da entrada atual + bias.

O vetor z_t ainda não é o novo estado final. Ele e apenas a combinacao linear inicial das influencias que atuam sobre o reservatório naquele instante.

3.4. Segundo passo: aplicar a não linearidade

Se usassemos diretamente z_t como novo estado, o modelo seria linear demais e perderia boa parte da riqueza que queremos em um reservatório. Por isso, aplicamos uma não linearidade componente a componente:

$$\widetilde{x}_t = \tanh(z_t).$$

Substituindo z_t, obtemos:

$$\widetilde{x}_t = \tanh(W_{res}x_{t-1} + W_{in}u_t + b).$$

O vetor $\widetilde{x}_t$ recebe o nome de **estado candidato**. Ele representa a resposta que o reservatório produziria se reagisse imediatamente ao passo atual.

A função $\tanh(\cdot)$ tem três papeis didaticamente importantes:

- introduz não linearidade;
- comprime os valores no intervalo $(-1, 1)$;
- ajuda a manter a dinâmica interna em uma faixa controlada.

Uma maneira simples de sentir isso e olhar alguns valores:

- se $z = 0.2$, entao $\tanh(0.2) \approx 0.197$;
- se $z = 3$, entao $\tanh(3) \approx 0.995$;
- se $z = -4$, entao $\tanh(-4) \approx -0.999$.

Isso mostra que a não linearidade não apenas "entorta"a resposta: ela também evita que os valores crescam sem limite.

3.5. Um exemplo com uma única unidade

Para tornar a ideia menos abstrata, imagine por um momento um reservatório com apenas uma unidade. Nesse caso, todos os vetores e matrizes viram escalares:

$$z_t = w_{res}x_{t-1} + w_{in}u_t + b.$$

Suponha:

- $x_{t-1} = 0.40$;
- $u_t = 0.70$;
- $w_{res} = 0.50$;
- $w_{in} = 1.20$;
- $b = -0.10$.

Entao:

$$z_t = 0.50 \cdot 0.40 + 1.20 \cdot 0.70 - 0.10 = 0.94.$$

Aplicando a não linearidade:

$$\widetilde{x}_t = \tanh(0.94) \approx 0.735.$$

Essa conta simples ajuda a visualizar o processo:

1. o passado contribui com uma parte;
2. a entrada atual contribui com outra parte;
3. tudo isso passa pela `tanh`;
4. o resultado se torna o estado candidato.

3.6. Terceiro passo: misturar memória e atualizacao nova

O reservatório ainda não adota $\widetilde{x}_t$ como estado final. Em vez disso, ele mistura parte da memória anterior com parte do estado candidato:

$$x_t = (1 - \alpha)x_{t-1} + \alpha\widetilde{x}_t.$$

Essa é a parte que transforma o reservatório em um sistema com memória controlada. O parametro α regula a velocidade da atualizacao:

- se α e pequeno, o sistema preserva mais memória e muda devagar;
- se α e grande, o sistema reage mais ao presente e muda mais rápido.

Voltando ao exemplo anterior, se $x_{t-1} = 0.40$, $\widetilde{x}_t \approx 0.735$ e $\alpha = 0.20$, entao:

$$x_t = 0.80 \cdot 0.40 + 0.20 \cdot 0.735 \approx 0.467.$$

O leitor deve notar o seguinte: o estado final x_t ainda carrega parte do passado. Ele não salta diretamente para o estado candidato.

3.7. A equação completa do reservatório

Agora sim podemos juntar os passos anteriores. Substituindo o estado candidato na equação de mistura, chegamos a dinâmica completa:

$$x_t = (1 - \alpha)x_{t-1} + \alpha \tanh(W_{res}x_{t-1} + W_{in}u_t + b).$$

A leitura guiada dessa expressão e:

- olhe para o passado: x_{t-1};
- combine esse passado com a entrada atual: $W_{res}x_{t-1} + W_{in}u_t + b$;
- aplique a não linearidade: $\tanh(\cdot)$;
- misture o resultado com a memória anterior usando α.

Essa leitura é mais importante do que decorar a formula.

3.8. Como isso aparece no código

No código, essa construcao aparece de forma quase literal em `EchoStateReservoir.step()`:

```
pre_activation = (
    self.recurrent_weights @ self.state
    + self.input_weights @ input_vector
    + self.bias
)
new_state = np.tanh(pre_activation)
self.state = (1.0 - self.config.leak_rate) * self.state + self.config.l
```

A correspondencia entre teoria e implementação fica mais fácil de ler quando usamos os mesmos três passos:

1. `pre_activation` corresponde a z_t;
2. `new_state` corresponde a $\widetilde{x}_t$;
3. `self.state = ...` corresponde a atualizacao final de x_t.

3.9. Como a previsão sai do estado interno

A dinâmica do reservatório produz uma representação temporal, mas ainda não produz a previsão final. Para isso, usamos um readout linear:

$$\hat{y}_t = W_{out}\phi_t, \qquad \phi_t = [1; u_t; x_t].$$

O vetor ϕ_t concatena três elementos:

- um termo constante, representado por `1`;
- a entrada atual u_t;
- o estado interno x_t.

Em linguagem simples, isso quer dizer: depois que o reservatório transforma a sequência em um estado interno, o readout aprende uma combinacao linear dessas informações para produzir a previsão.

No projeto, `\phi_t` e construída por `_feature_vector()` e `W_out` e ajustado via regressão Ridge.

4. O que é treinado e o que não é treinado

Um dos pontos mais didáticos de RC e a divisão entre dinâmica fixa e leitura treinável.

No projeto:

- `W_in`, `W_res` e `b` sao inicializados aleatoriamente e mantidos fixos;
- apenas o readout linear e ajustado com supervisão.

Formalmente, o treinamento resolve

$$W_{out}^* = \arg\min_{W_{out}} \|Y - \Phi W_{out}\|_2^2 + \lambda \|W_{out}\|_2^2,$$

em que Φ é a matriz de features acumuladas ao longo do tempo e λ é o hiperparâmetro de regularização Ridge.

Essa escolha reduz o custo de treinamento em relação a RNNs totalmente treináveis e, ao mesmo tempo, preserva uma representação temporal rica.

5. Como o tempo entra no modelo

No projeto, o vetor de entrada sequencial e construído em `code/common/sequential_features.py` com sete componentes:

- demanda prévia normalizada;
- promoção normalizada;
- `dow_sin`, `dow_cos`;
- `month_sin`, `month_cos`;
- indicador de fim de semana.

Em notação compacta,

$$u_t = \begin{bmatrix} \widetilde{y}_{t-1} & \widetilde{p}_t & \sin(2\pi\,\mathrm{dow}_t/7) & \cos(2\pi\,\mathrm{dow}_t/7) & \sin(2\pi\,\mathrm{month}_t/12) & \cos(2\pi\,\mathrm{month}_t/12) & \mathbb{1}_{\mathrm{weekend}} \end{bmatrix}^\top$$

Esse vetor coloca em uma mesma representação:

- memória de curtissimo prazo, via $\widetilde{y}_{t-1}$;
- contexto exógeno, via promoção;
- ciclo temporal, via senos e cossenos.

6. O papel do washout

Nos primeiros instantes da simulação, o estado do reservatório ainda esta fortemente contaminado pela inicialização. Por isso, o projeto descarta os primeiros passos antes de treinar o readout.

Se chamarmos o `washout` de w, o treino do readout usa apenas os tempos $t \geq w$:

$$\Phi = [\phi_w, \phi_{w+1}, \ldots, \phi_T]^\top.$$

Em `fit_rc_readout()`, isso aparece no teste `if idx >= config.washout`.

O `washout` não é um detalhe de implementação. Ele e uma parte conceitual do pipeline, porque separa a transiente inicial da dinâmica que realmente queremos aproveitar.

7. Como o projeto implementa RC no caso Favorita

A tabela abaixo resume o pipeline implementado.

Objeto	Dimensão no projeto	Origem
Vetor de entrada u_t	7	`scaled_input_vector()`
Estado do reservatório x_t	80	`RCConfig.n_reservoir`
Vetor de features $[1; u_t; x_t]$	88	`_feature_vector()`
Readout	1 saida	Ridge linear sobre as features

O fluxo completo do código e o seguinte:

1. `build_scaler_state()` calcula médias e desvios para normalizacao;
2. `scaled_input_vector()` constroi u_t;
3. `EchoStateReservoir.step()` atualiza x_t;
4. `_feature_vector()` monta $\phi_t = [1; u_t; x_t]$;
5. `Ridge.fit()` estima o readout;
6. `forecast_rc()` faz previsão recursiva no bloco de teste.

O trecho central do treinamento e este:

```
input_vector = scaled_input_vector(prev_y, row, scaler=scaler)
state = reservoir.step(input_vector)
feature_rows.append(_feature_vector(state, input_vector))
targets.append(float(row["y"]))
```

Isso mostra a ideia central de RC em sua forma mais simples: o modelo não aprende uma representação temporal diretamente por backpropagation; ele coleta estados dinamicos e aprende apenas como le-los.

8. O que os artefatos intermediários mostram

O artigo não precisa esperar a métrica final para ensinar alguma coisa. Os artefatos computacionais deste modulo mostram o pipeline em um nível mais interno.

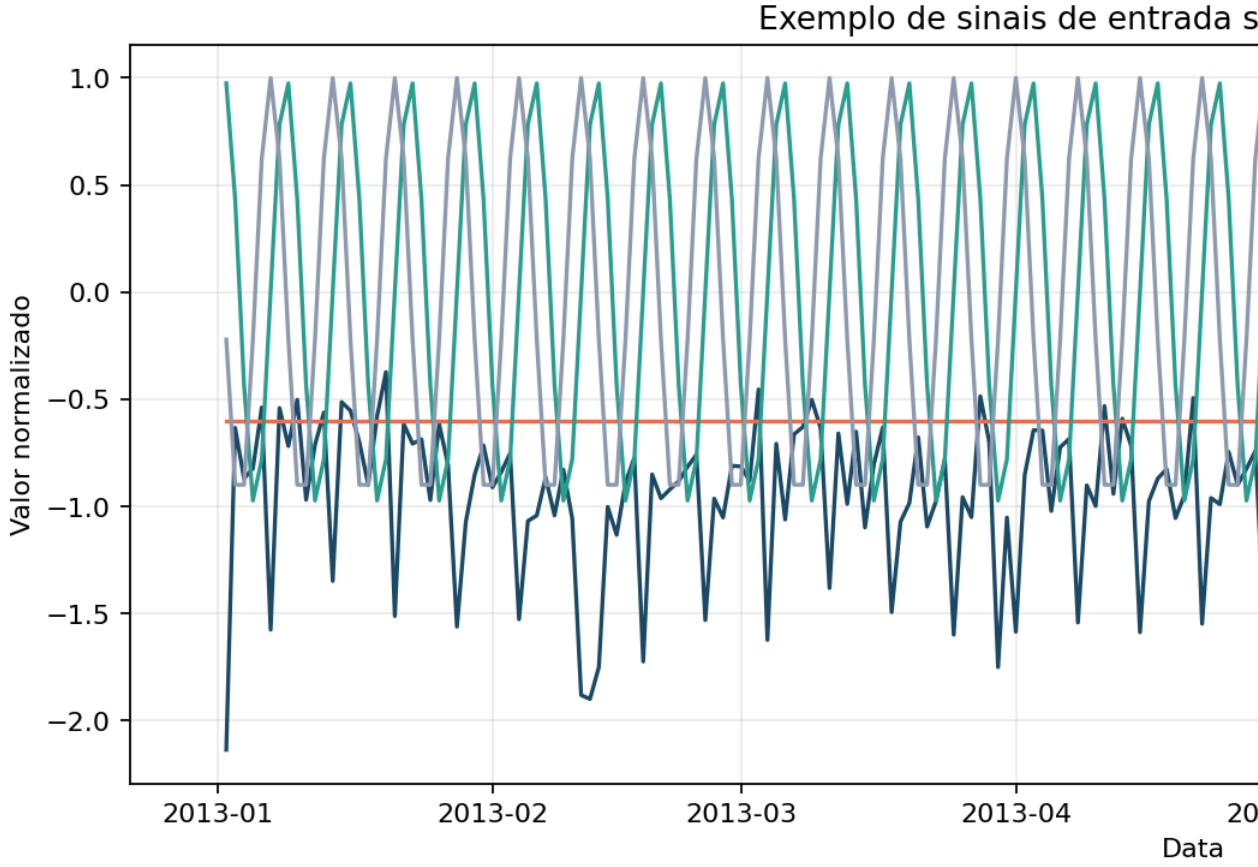

A imagem de entrada sequencial mostra que o reservatório não recebe apenas uma série de vendas crua. Ele recebe uma codificacao temporal e exógena compacta.

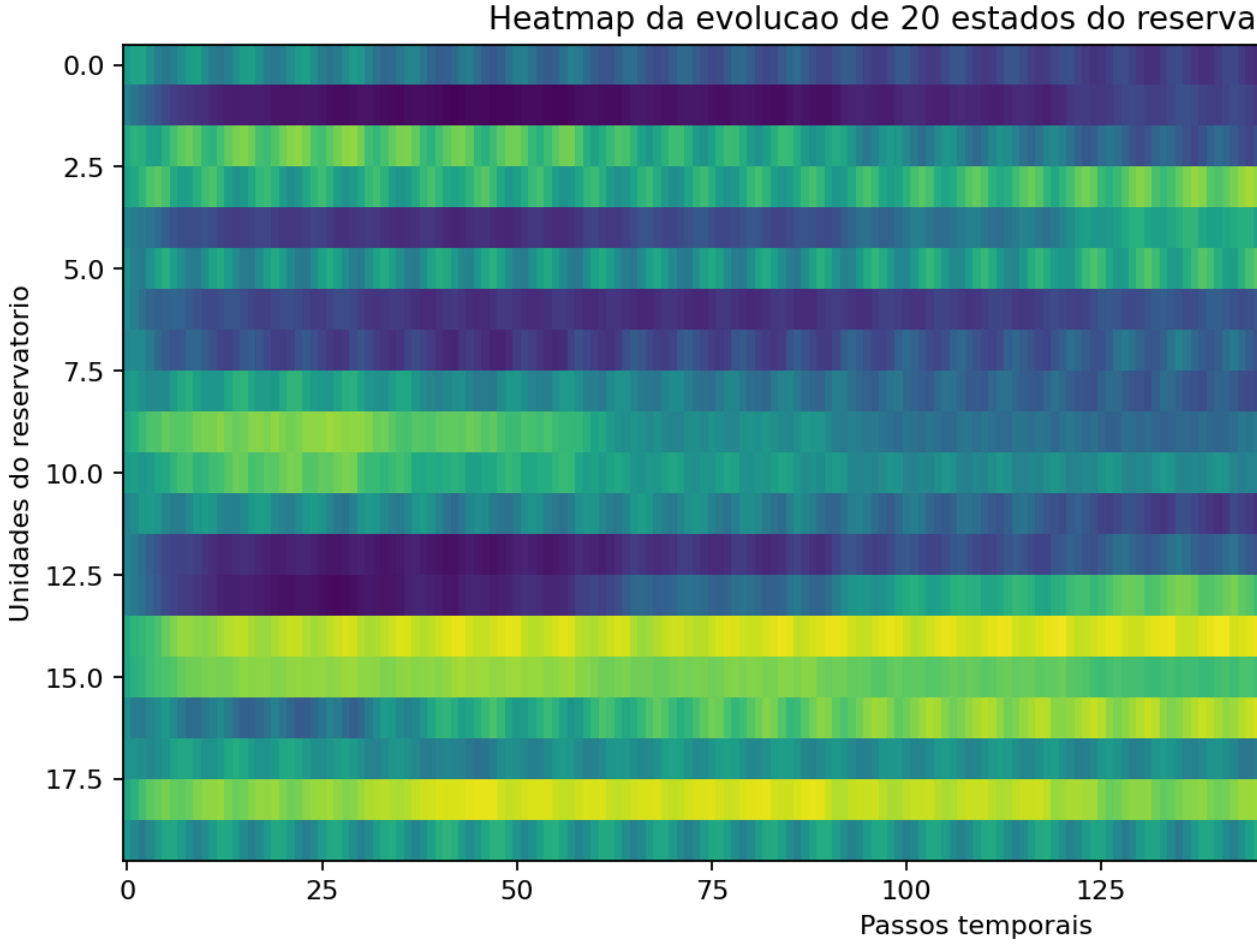

O heatmap dos estados ilustra duas ideias importantes:

1. unidades diferentes respondem de modos diferentes ao mesmo estimulo;
2. a memória do reservatório não é um único lag explícito, mas uma combinacao distribuída de estados.

Em outras palavras, RC constroi uma base dinâmica de features sem precisar enumerar manualmente toda a interação temporal. Isso sustenta bem a **qualidade conceitual da representação interna**, mas ainda não diz, por si só, se a previsão final e forte.

9. Como avaliar a qualidade do RC sem misturar conceitos

A avaliação do RC fica mais clara quando separamos três perguntas que muitas vezes sao misturadas.

Eixo de avaliação	Pergunta correta	Evidencia usada neste artigo
Representação interna	Os estados reagem de forma heterogenea, não linear e com memória distribuíd	
Previsão final	O readout produz erro baixo no mesmo split e contra baselines honestos?	
Estabilidade experimental	O resultado se sustenta quando seed e hiperparâmetros mudam?	

Essa separacao evita um erro comum: tratar um heatmap interessante como prova suficiente de que a saida prevista e boa. Um estado interno pode ser didaticamente con-

vincente e, ainda assim, produzir uma previsão final medíocre se o readout receber uma dinâmica mal configurada.

10. Primeira evidencia quantitativa da saida do RC

A tabela abaixo posiciona o RC default contra duas referencias honestas no mesmo bloco de teste de `90` dias.

Modelo	Janela	MAE	RMSE	WAPE	sMAPE
ETS	teste (90 dias)	216.303	307.638	0.0999	0.1042
Seasonal Naive	teste (90 dias)	259.067	352.280	0.1196	0.1361
RC default	teste (90 dias)	324.294	423.417	0.1498	0.1653

Duas leituras importam aqui:

1. o RC default funciona de ponta a ponta: ele gera previsões finitas, mede erro e pode ser comparado sob o mesmo protocolo temporal;
2. isso ainda não basta para chama-lo de melhor solucao neste recorte: seu `MAE` ficou 25.2% acima do `Seasonal Naive` e 49.9% acima do `ETS`.

Esse ponto é central para a honestidade científica do texto. O artigo agora não apenas explica **como** o RC funciona; ele também mostra **o que a configuração default entrega** quando confrontada com baselines sérios.

11. Estabilidade experimental: a seed também faz parte da historia

Um único run pode dar uma impressao excessivamente otimista ou pessimista sobre RC. Por isso, executamos dez seeds para três configurações simples.

Configuração	Seeds	MAE	RMSE	WAPE	sMAPE
default	10	565.337 +/- 504.007	686.563 +/- 570.807	0.2611 +/- 0.2327	0.2557 +
sr = 0.20	10	477.982 +/- 285.463	604.875 +/- 373.503	0.2207 +/- 0.1318	0.2269 +
sr = 0.20, leak = 0.30	10	453.504 +/- 230.676	576.555 +/- 325.866	0.2094 +/- 0.1065	0.2185 +

Três fatos se destacam:

1. a configuração default apresentou alta variabilidade: `MAE` médio de 565.337 com desvio-padrão de 504.007;
2. no default, a faixa observada foi larga: de 275.064 até 1966.124;
3. um ajuste simples para `spectral_radius = 0.20` e `leak_rate = 0.30` reduziu o `MAE` médio em 19.8% e o desvio-padrão em 54.2% em relação ao default.

Esse resultado não invalida o RC. Ele mostra algo mais útil: o desempenho do reservatório depende do regime dinamico em que ele opera. Em outras palavras, `seed` e hiperparâmetros fazem parte da qualidade experimental do modelo.

12. O que o washout realmente controla

O `washout` decide quantos passos iniciais sao descartados antes de o readout ver os estados internos. Conceitualmente, ele separa transiente de inicialização de dinâmica útil. Experimentalmente, ele muda o erro.

Washout	MAE	RMSE	WAPE	sMAPE
0	325.718	411.319	0.1504	0.1651
7	317.567	402.268	0.1466	0.1613
14	324.294	423.417	0.1498	0.1653
21	327.744	434.786	0.1513	0.1677
28	334.848	446.066	0.1546	0.1722
42	330.511	439.718	0.1526	0.1695

Neste recorte, `washout = 7` foi o melhor valor entre os testados, com `MAE = 317.567`. A licao pratica e simples:

- `washout` muito curto pode contaminar o readout com estados ainda dominados pela inicialização;
- `washout` excessivo desperdica observações úteis de treino.

13. Como escolher os hiperparâmetros centrais sem adivinhar

O leitor não precisa decorar uma grade enorme de tuning para começar. O mais importante e entender o papel de cada hiperparâmetro e que tipo de comportamento esperar quando ele varia.

Hiperparâmetro	Papel	Faixa inicial pratica	Evidencia no recorte
`spectral_radius`	controla persistencia e regime dinamico do reservatório	`0.20` a `0.60`	
`leak_rate`	controla a velocidade de atualizacao do estado	`0.10` a `0.30`	
`washout`	remove o transiente de inicialização antes do treino do readout	`7` a `21`	
`n_reservoir`	define a capacidade representacional do estado interno	`80` como ponto c	

O ponto didático aqui e decisivo: `spectral_radius`, `leak_rate`, `washout` e `n_reservoir` não sao botoes arbitrarios. Eles controlam memória, velocidade de resposta, uso do transiente e capacidade representacional.

14. O que este artigo já prova, e o que ainda deixa em aberto

14.1. O que já esta claro

- a representação interna do RC e boa como mecanismo conceitual: os estados sao heterogeneos, não lineares e coerentes com a ideia de memória distribuída;
- a previsão final do RC e mensuravel e comparavel; portanto, o artigo já não depende apenas de intuição;
- a estabilidade experimental precisa ser reportada de forma explícita, porque a variação por seed e relevante.

14.2. O que ainda não esta encerrado

- este artigo ainda não fecha o benchmark completo da série;
- ele não substitui uma comparação ampla com `Prophet`, `XGBoost`, `LSTM` e `QRC`;
- ele não pretende vender o RC como melhor modelo neste recorte, e sim estabelecer uma base correta para julga-lo.

Essa delimitacao melhora o artigo, porque troca promessa vaga por evidencia observável.

15. Passo-a-passo para estudar ou modificar o RC do projeto

Um leitor que queira estudar a implementação deve seguir esta ordem:

1. abrir `code/common/sequential_features.py`;
2. verificar como o vetor `u_t` e construído;
3. abrir `code/rc/model.py` e localizar `RCConfig`;
4. ler `EchoStateReservoir.step()` junto da equação do artigo;
5. ler `fit_rc_readout()` e localizar o `washout`;
6. executar `python code/rc/run.py`;
7. validar o comportamento com `pytest code/rc/test_model.py`.

Essa ordem importa. Se o leitor abrir apenas `run.py`, perde a correspondencia entre teoria e implementação.

16. Conclusão

RC agora esta formulado no contexto do projeto com um nível maior de rigor. O artigo continua didático, mas deixa de depender apenas de intuição: ele mostra como o estado interno evolui, como a previsão sai do readout e como medir, de forma honesta, se essa saida e boa e estável. A resposta correta para este recorte e clara: a representação interna do RC e forte como objeto conceitual; a previsão final default e promissora, mas ainda inferior a baselines clássicos fortes; e a estabilidade experimental exige cuidado com seed e hiperparâmetros. Isso prepara melhor o leitor para os artigos seguintes, porque o próximo passo deixa de ser "confiar no RC"e passa a ser "testar o RC com método".

Entregaveis associados no repositorio

- implementação do RC: `code/rc/model.py`
- execucao do RC: `code/rc/run.py`
- testes do RC: `code/rc/test_model.py`
- construcao de entrada sequencial: `code/common/sequential_features.py`
- leitura quantitativa inicial: `computational_results_20260407_000554/rc_quality_`
- estabilidade em múltiplas seeds: `computational_results_20260407_000554/rc_seed`
- sweep de `washout`: `computational_results_20260407_000554/rc_washout_swe`
- artefatos deste artigo: `computational_results_20260407_000554/`

17. Referências

Referências

[1] JAEGER, H. **The "echo state" approach to analysing and training recurrent neural networks**. Bonn: German National Research Center for Information Technology (GMD), 2001.

[2] LUKOSEVICIUS, M.; JAEGER, H. **Reservoir computing approaches to recurrent neural network training**. *Computer Science Review*, v. 3, n. 3, p. 127–149, 2009.

[3] LUKOSEVICIUS, M. **A practical guide to applying echo state networks**. In: MONTAVON, G.; ORR, G. B.; MÜLLER, K.-R. (org.). *Neural Networks: Tricks of the Trade*. 2. ed. Berlin: Springer, 2012. p. 659–686.

[4] FUJII, K.; NAKAJIMA, K. **Harnessing disordered-ensemble quantum dynamics for machine learning**. *Physical Review Applied*, v. 8, n. 2, 024030, 2017.