Primeiro pipeline reproduzivel: previsao de demanda no Favorita com baselines e RC

Resumo. *Este artigo transforma a teoria dos dois primeiros capitulos em um pipeline reproduzivel de previsao. O objetivo e ensinar o leitor a executar um baseline forte e um primeiro modelo de Reservoir Computing no mesmo recorte adotado no Favorita, medindo ambos com o mesmo protocolo temporal. Fazemos isso em modo passo-a-passo: carregamos a serie, separamos treino e teste, executamos* `Seasonal Naive`*, executamos RC, comparamos previsoes, interpretamos metricas e discutimos por que perder para um baseline nao invalida um experimento didatico. O resultado principal e honesto: no recorte inicial,* `Seasonal Naive` *supera o RC em todas as metricas, mas o RC funciona de ponta a ponta e abre as perguntas certas para os artigos seguintes.*

0.1. 1. O que o leitor vai aprender

Ao final deste artigo, voce sera capaz de:

1. executar um pipeline minimo de previsao no Favorita;
2. usar `Seasonal Naive` como baseline serio, e nao apenas ilustrativo;
3. rodar o RC classico do projeto do inicio ao fim;
4. comparar previsoes com as mesmas metricas e o mesmo split temporal;
5. interpretar um resultado inicial ruim como parte do processo cientifico.

0.2. 2. O recorte experimental herdado

Continuamos usando exatamente o mesmo recorte estabelecido no artigo 1:

- `store_nbr = 1`
- `family = BEVERAGES`
- frequencia diaria
- ultimos `90` dias como teste

Isso significa que a comparacao deste artigo e justa por construcao. Ambos os modelos veem os mesmos dados e sao avaliados pelas mesmas metricas.

0.3. 3. Passo 1: carregar a serie e separar treino e teste

O pipeline comeca com as funcoes de `code/common/favorita.py`.

```
config = FavoritaSeriesConfig()
frame = load_store_family_series(store_nbr=config.store_nbr, family=con
train, test = temporal_train_test_split(frame, test_days=config.test_da
```

Em notacao temporal, o experimento usa

$$\mathcal{D}_{train} = \{(x_t, y_t)\}_{t=1}^{T-90}, \qquad \mathcal{D}_{test} = \{(x_t, y_t)\}_{t=T-89}^{T}.$$

Esse split e fundamental. Se ele mudar entre os modelos, a comparacao deixa de ser confiavel.

0.4. 4. Passo 2: executar o baseline `Seasonal Naive`

O baseline sazonal do projeto esta em `code/baselines/seasonal_naives/model.py` e implementa a regra

$$\hat{y}_t = y_{t-7},$$

usando sazonalidade semanal.

A implementacao e curta exatamente porque sua funcao pedagogica e clara:

```
pattern = train["y"].to_numpy()[-season_length:]
repeats = int(np.ceil(horizon / season_length))
forecast = np.tile(pattern, repeats)[:horizon]
```

Para executar:

```
python code/baselines/seasonal_naives/run.py
pytest code/baselines/seasonal_naives/test_model.py
```

Um bom artigo de series temporais nao pula esta etapa. Se um modelo mais sofisticado nao supera esse baseline, isso precisa aparecer no texto.

0.5. 5. Passo 3: executar o primeiro RC

O RC classico do projeto esta em `code/rc/model.py` e usa a configuracao default:

- `n_reservoir = 80`
- `spectral_radius = 0.6`
- `leak_rate = 0.15`
- `washout = 14`

A dinamica do reservatorio e

$$x_t = (1-\alpha)x_{t-1} + \alpha \tanh(W_{res}x_{t-1} + W_{in}u_t + b),$$

e o readout resolve uma regressao Ridge sobre

$$\phi_t = [1; u_t; x_t].$$

Para executar:

```
python code/rc/run.py
pytest code/rc/test_model.py
```

0.6. 6. Passo 4: medir com o mesmo protocolo

As quatro metricas usadas na comparacao sao:

$$\text{MAE}, \quad \text{RMSE}, \quad \text{WAPE}, \quad \text{sMAPE}.$$

O ponto metodologico aqui e simples, mas decisivo: os modelos precisam ser comparados no mesmo horizonte, com as mesmas observacoes de teste e as mesmas regras de previsao recursiva.

0.7. 7. Resultados iniciais

Os resultados reais obtidos no projeto foram os seguintes.

Modelo	MAE	RMSE	WAPE	sMAPE
Seasonal Naive	259.067	352.280	0.1196	0.1361
RC	324.294	423.417	0.1498	0.1653

O `Seasonal Naive` supera o RC em todas as metricas. Em particular:

- o `MAE` do RC ficou 25.2% acima do baseline sazonal;
- o `RMSE` do RC ficou 20.2% acima do baseline sazonal.

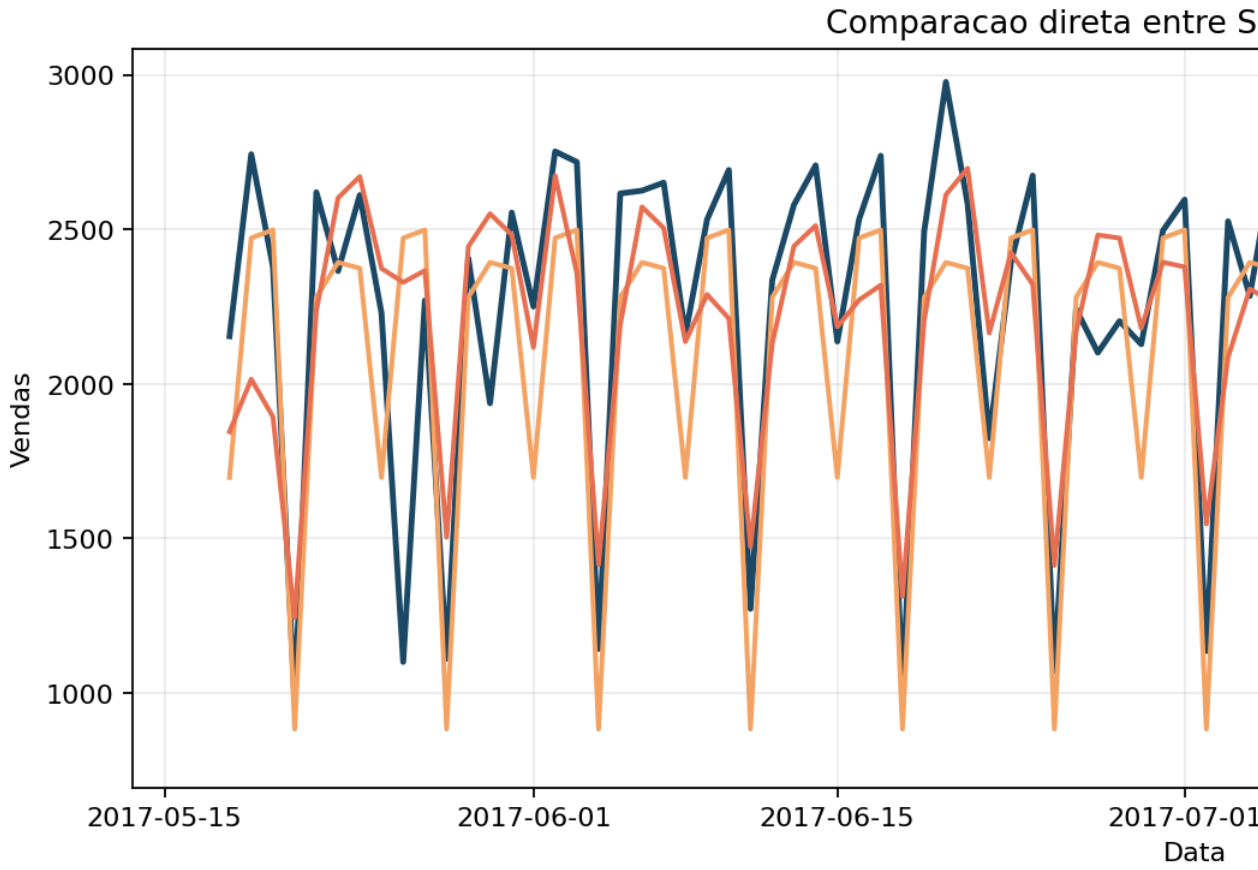

A sobreposicao das previsoes ajuda a ler o resultado com mais cuidado do que a tabela numerica isolada:

- o baseline acompanha melhor o padrao semanal;
- o RC funciona, mas ainda oscila mais em torno da serie observada;
- o erro do RC nao vem de um colapso do pipeline, e sim de representacao insuficiente para este primeiro ajuste.

0.8. 8. O que este experimento ensina

O experimento e didaticamente valioso por quatro motivos.

0.8.1. 8.1 Baseline forte nao e detalhe

Em series temporais, um baseline sazonal simples pode ser surpreendentemente competitivo. Isso vale especialmente quando o sinal semanal e forte, como no caso de bebidas no recorte adotado no Favorita.

0.8.2. 8.2 RC nao deve ser tratado como magia

O RC funciona de ponta a ponta: carrega dados, constroi representacao, treina readout e produz previsoes. Mas funcionar nao e o mesmo que vencer. O artigo faz questao de manter essa distincao.

0.8.3. 8.3 Reprodutibilidade e uma conquista em si

Este pipeline deixa um trilho completo:

- codigo de carregamento;
- execucao do baseline;
- execucao do RC;
- testes;
- metricas salvas;
- imagens comparativas.

Essa cadeia e o que permite que os artigos seguintes falem de tuning, avaliacao justa e QRC sem perder a base experimental.

0.8.4. 8.4 Derrota inicial organiza as proximas perguntas

Como o RC perdeu para o baseline, os artigos seguintes precisam responder:

- o tamanho do reservatorio esta adequado?
- a memoria do modelo esta curta ou longa demais?
- o raio espectral esta instavel?
- o leak rate esta ajudando ou atrapalhando?

Em um bom percurso didatico, resultados fracos produzem perguntas fortes.

0.9. 9. Como este artigo se conecta ao benchmark maior

O experimento deste artigo nao encerra a comparacao. Ele apenas estabelece o primeiro patamar:

- `Seasonal Naive` sera mantido como referencia;
- RC sera refinado e estudado com mais detalhe;
- novos competidores entrarao depois: `ETS`, `Prophet`, `XGBoost`, `LSTM` e `QRC`.

Essa progressao e importante porque impede um salto artificial do "primeiro RC"diretamente para o "QRC final".

0.10. 10. Conclusao

O primeiro pipeline reproduzivel da serie esta fechado. O baseline sazonal venceu, o RC funcionou sem vencer e o leitor ja tem um experimento concreto para estudar, modificar e rerodar. Isso e exatamente o que um artigo didatico deveria entregar neste ponto: menos promessas vagas e mais reproducao concreta.

O proximo artigo vai usar essa base para explicar por que RC pode melhorar ou piorar tanto quando seus hiperparametros mudam.

0.11. Entregaveis associados no repositorio

- baseline sazonal: `code/baselines/seasonal_naives/`
- RC classico: `code/rc/`
- comparacao numerica e visual deste artigo: `computational_results_20260402_222902/`
- figuras principais: `baseline_vs_rc_overlay.png`, `seasonal_naive_forecast_plot.png`, `rc_forecast_plot.png`

0.12. Referencias

- Hyndman, R. J.; Athanasopoulos, G. Forecasting: Principles and Practice.
- Jaeger, H. The "echo state"approach to analysing and training recurrent neural networks.
- Lukosevicius, M. A practical guide to applying echo state networks.