Primeiro pipeline reproduzível: previsão de demanda no Favorita com baselines e RC

Resumo. *Este artigo transforma a teoria dos dois primeiros capítulos em um pipeline reproduzível de previsão. O objetivo é ensinar o leitor a executar um baseline forte e um primeiro modelo de Reservoir Computing no mesmo recorte adotado no Favorita, medindo ambos com o mesmo protocolo temporal. Fazemos isso em modo passo-a-passo: carregamos a série, separamos treino e teste, executamos* `Seasonal Naive`*, executamos RC, comparamos previsões, interpretamos métricas e discutimos por que perder para um baseline não invalida um experimento didático. O resultado principal e honesto: no recorte inicial,* `Seasonal Naive` *supera o RC em todas as métricas, mas o RC funciona de ponta a ponta e abre as perguntas certas para os artigos seguintes.*

1. O que o leitor vai aprender

Ao final deste artigo, você será capaz de:

1. executar um pipeline mínimo de previsão no Favorita;
2. usar `Seasonal Naive` como baseline serio, e não apenas ilustrativo;
3. rodar o RC clássico do projeto do inicio ao fim;
4. comparar previsões com as mesmas métricas e o mesmo split temporal;
5. interpretar um resultado inicial ruim como parte do processo científico.

2. O recorte experimental herdado

Continuamos usando exatamente o mesmo recorte estabelecido no artigo 1:

- `store_nbr = 1`
- `family = BEVERAGES`
- frequência diária
- últimos `90` dias como teste

Isso significa que a comparação deste artigo e justa por construcao. Ambos os modelos veem os mesmos dados e sao avaliados pelas mesmas métricas.

3. Passo 1: carregar a série e separar treino e teste

O pipeline começa com as funções de `code/common/favorita.py`.

```
config = FavoritaSeriesConfig()
frame = load_store_family_series(store_nbr=config.store_nbr, family=con
train, test = temporal_train_test_split(frame, test_days=config.test_da
```

Em notação temporal, o experimento usa

$$\mathcal{D}_{train} = \{(x_t, y_t)\}_{t=1}^{T-90}, \qquad \mathcal{D}_{test} = \{(x_t, y_t)\}_{t=T-89}^{T}.$$

Esse split e fundamental. Se ele mudar entre os modelos, a comparação deixa de ser confiavel.

4. Passo 2: executar o baseline `Seasonal Naive`

O baseline sazonal do projeto esta em `code/baselines/seasonal_naives/model.py` e implementa a regra

$$\hat{y}_t = y_{t-7},$$

usando sazonalidade semanal.

A implementação é curta exatamente porque sua função pedagógica e clara:

```
pattern = train["y"].to_numpy()[-season_length:]
repeats = int(np.ceil(horizon / season_length))
forecast = np.tile(pattern, repeats)[:horizon]
```

Para executar:

```
python code/baselines/seasonal_naives/run.py
pytest code/baselines/seasonal_naives/test_model.py
```

Um bom artigo de séries temporais não pula esta etapa. Se um modelo mais sofisticado não supera esse baseline, isso precisa aparecer no texto.

5. Passo 3: executar o primeiro RC

O RC clássico do projeto esta em `code/rc/model.py` e usa a configuração default:

- `n_reservoir = 80`
- `spectral_radius = 0.6`
- `leak_rate = 0.15`
- `washout = 14`

A dinâmica do reservatório é

$$x_t = (1-\alpha)x_{t-1} + \alpha \tanh(W_{res}x_{t-1} + W_{in}u_t + b),$$

e o readout resolve uma regressão Ridge sobre

$$\phi_t = [1; u_t; x_t].$$

Para executar:

```
python code/rc/run.py
pytest code/rc/test_model.py
```

6. Passo 4: medir com o mesmo protocolo

As quatro métricas usadas na comparação sao:

$$\text{MAE}, \quad \text{RMSE}, \quad \text{WAPE}, \quad \text{sMAPE}.$$

O ponto metodológico aqui é simples, mas decisivo: os modelos precisam ser comparados no mesmo horizonte, com as mesmas observações de teste e as mesmas regras de previsão recursiva.

7. Resultados iniciais

Os resultados reais obtidos no projeto foram os seguintes.

Modelo	MAE	RMSE	WAPE	sMAPE
Seasonal Naive	259.067	352.280	0.1196	0.1361
RC	324.294	423.417	0.1498	0.1653

O `Seasonal Naive` supera o RC em todas as métricas. Em particular:

- o `MAE` do RC ficou 25.2% acima do baseline sazonal;
- o `RMSE` do RC ficou 20.2% acima do baseline sazonal.

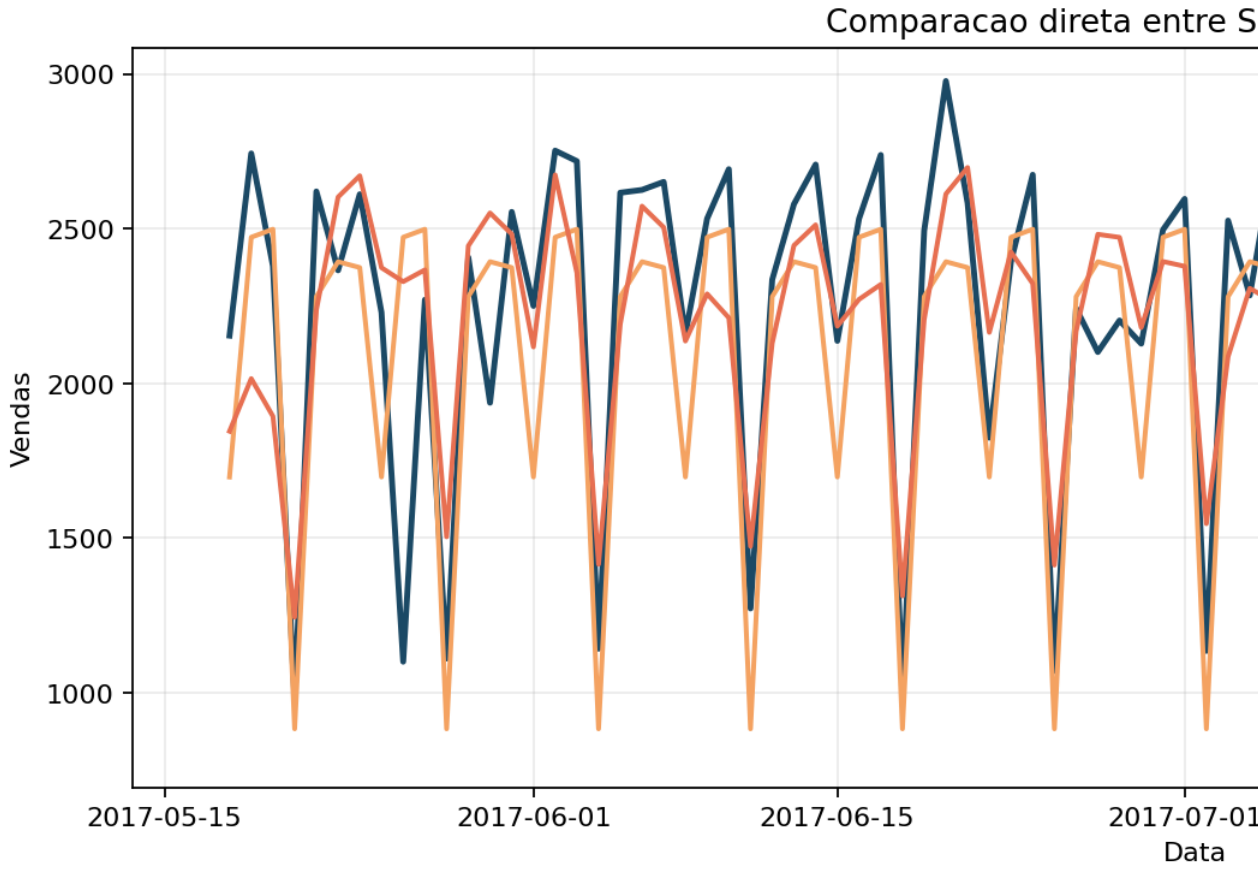

A sobreposicao das previsões ajuda a ler o resultado com mais cuidado do que a tabela numerica isolada:

- o baseline acompanha melhor o padrão semanal;
- o RC funciona, mas ainda oscila mais em torno da série observada;
- o erro do RC não vem de um colapso do pipeline, e sim de representação insuficiente para este primeiro ajuste.

8. O que este experimento ensina

O experimento é didaticamente valioso por quatro motivos.

8.1. Baseline forte não é detalhe

Em séries temporais, um baseline sazonal simples pode ser surpreendentemente competitivo. Isso vale especialmente quando o sinal semanal e forte, como no caso de bebidas no recorte adotado no Favorita.

8.2. RC não deve ser tratado como magia

O RC funciona de ponta a ponta: carrega dados, constroi representação, treina readout e produz previsões. Mas funcionar não é o mesmo que vencer. O artigo faz questão de manter essa distinção.

8.3. Reprodutibilidade e uma conquista em si

Este pipeline deixa um trilho completo:

- código de carregamento;
- execucao do baseline;
- execucao do RC;
- testes;
- métricas salvas;
- imagens comparativas.

Essa cadeia e o que permite que os artigos seguintes falem de tuning, avaliação justa e QRC sem perder a base experimental.

8.4. Derrota inicial organiza as próximas perguntas

Como o RC perdeu para o baseline, os artigos seguintes precisam responder:

- o tamanho do reservatório esta adequado?
- a memória do modelo esta curta ou longa demais?
- o raio espectral esta instável?
- o leak rate esta ajudando ou atrapalhando?

Em um bom percurso didático, resultados fracos produzem perguntas fortes.

9. Como este artigo se conecta ao benchmark maior

O experimento deste artigo não encerra a comparação. Ele apenas estabelece o primeiro patamar:

- `Seasonal Naive` será mantido como referencia;
- RC será refinado e estudado com mais detalhe;
- novos competidores entrarao depois: `ETS`, `Prophet`, `XGBoost`, `LSTM` e `QRC`.

Essa progressao e importante porque impede um salto artificial do "primeiro RC"diretamente para o "QRC final".

10. Conclusão

O primeiro pipeline reproduzível da série esta fechado. O baseline sazonal venceu, o RC funcionou sem vencer e o leitor já tem um experimento concreto para estudar, modificar e rerodar. Isso é exatamente o que um artigo didático deveria entregar neste ponto: menos promessas vagas e mais reprodução concreta.

O próximo artigo vai usar essa base para explicar por que RC pode melhorar ou piorar tanto quando seus hiperparametros mudam.

11. Entregaveis associados no repositorio

- baseline sazonal: `code/baselines/seasonal_naives/`
- RC clássico: `code/rc/`
- comparação numerica e visual deste artigo: `computational_results_20260402_222902/`
- figuras principais: `baseline_vs_rc_overlay.png`, `seasonal_naive_forecast_plot.png`, `rc_forecast_plot.png`

12. Referências

Referências

[1] JAEGER, H. **The "echo state" approach to analysing and training recurrent neural networks**. Bonn: German National Research Center for Information Technology (GMD), 2001.

[2] LUKOSEVICIUS, M.; JAEGER, H. **Reservoir computing approaches to recurrent neural network training**. *Computer Science Review*, v. 3, n. 3, p. 127–149, 2009.

[3] LUKOSEVICIUS, M. **A practical guide to applying echo state networks**. In: MONTAVON, G.; ORR, G. B.; MÜLLER, K.-R. (org.). *Neural Networks: Tricks of the Trade*. 2. ed. Berlin: Springer, 2012. p. 659–686.

[4] FUJII, K.; NAKAJIMA, K. **Harnessing disordered-ensemble quantum dynamics for machine learning**. *Physical Review Applied*, v. 8, n. 2, 024030, 2017.