Por que Reservoir Computing funciona: memória, não linearidade e capacidade de representação

Resumo. *Este artigo responde a pergunta que ficou aberta depois do primeiro pipeline: por que o desempenho do RC muda tanto quando ajustamos seus hiperparametros? Para responder, conectamos memória, não linearidade e capacidade de representação a resultados computacionais reais do projeto. Começamos por uma leitura teórica do reservatório, mostramos como o* `leak_rate` *controla a escala temporal efetiva, como o* `spectral_radius` *influencia estabilidade e mistura e como o tamanho do reservatório afeta a base de representação. Em seguida, analisamos os resultados de varreduras reais sobre* `n_reservoir`*,* `spectral_radius` *e* `leak_rate`*. O artigo não apenas explica RC em abstrato: ele mostra o que essas ideias produzem, ou destroem, no recorte adotado no Favorita.*

1. O que o leitor vai aprender

Ao final deste artigo, você será capaz de:

1. explicar memória e não linearidade no RC em termos matemáticos;
2. entender por que `spectral_radius` e `leak_rate` mudam o comportamento do modelo;
3. interpretar tabelas de tuning do RC;
4. diferenciar capacidade de representação de mera quantidade de unidades;
5. decidir o que vale testar antes de partir para QRC.

2. Memória: o passado precisa continuar presente

Em RC, a memória não aparece como um vetor de lags explicitamente escrito. Ela aparece no proprio estado do reservatório. Se linearizarmos a dinâmica em torno de uma regiao pequena, obtemos aproximadamente

$$x_t \approx Ax_{t-1} + \alpha W_{in} u_t + \alpha b, \qquad A = (1-\alpha)I + \alpha W_{res}.$$

Desdobrando a recursao:

$$x_t \approx \sum_{k=0}^{\infty} A^k (\alpha W_{in} u_{t-k} + \alpha b).$$

Essa expressao mostra a intuição correta: o estado atual e uma superposicao ponderada do passado. A velocidade com que o passado "desaparece"depende da matriz efetiva A, logo depende de `spectral_radius` e `leak_rate`.

2.1. O papel do leak rate

O `leak_rate` regula quanto do estado novo substitui o estado antigo. Valores pequenos alongam a memória; valores grandes tornam a resposta mais reativa.

No projeto, o `leak_rate` default foi `0.15`, mas a varredura mostrou que `0.30` melhora levemente o resultado neste recorte.

leak_rate	MAE	RMSE	WAPE	sMAPE
0.05	388.180	491.504	0.1793	0.1982
0.1	357.675	474.461	0.1652	0.1822
0.15	324.294	423.417	0.1498	0.1653
0.3	317.767	419.947	0.1467	0.1621
0.5	770.680	1035.544	0.3559	0.5702

Esse resultado ensina uma licao importante: uma memória mais longa não é automaticamente melhor. Se a série responde fortemente a promoção e sazonalidade semanal, uma resposta um pouco mais rapida pode ajudar.

2.2. O papel do washout

O `washout` separa o regime transiente inicial da dinâmica útil para treino:

$$\Phi = [\phi_w, \phi_{w+1}, \ldots, \phi_T]^\top.$$

Sem `washout`, o readout pode aprender artefatos de inicialização em vez de aprender uma representação estabilizada da série.

3. Não linearidade: por que a série não cabe em uma regra unica

O reservatório usa a não linearidade `tanh`:

$$\widetilde{x}_t = \tanh(W_{res}x_{t-1} + W_{in}u_t + b).$$

Essa não linearidade e o que permite ao modelo misturar efeitos de calendário, promoção e demanda prévia sem impor uma relação puramente aditiva ou puramente linear.

Em previsão de demanda, isso importa porque:

- a mesma promoção pode gerar efeitos diferentes em dias diferentes;
- o mesmo dia da semana pode ter resposta diferente dependendo do histórico imediato;
- a relação entre passado e presente não precisa ser monotona nem linear.

4. Capacidade de representação: tamanho importa, mas não sozinho

Um erro comum de iniciantes e supor que "mais unidades"sempre significa "mais desempenho". A varredura de `n_reservoir` no projeto mostra o contrario.

n_reservoir	MAE	RMSE	WAPE	sMAPE
40	1278.623	1721.270	0.5904	0.4393
80	324.294	423.417	0.1498	0.1653
120	394.030	464.884	0.1820	0.2026
160	430.945	565.166	0.1990	0.2359

A configuração `n_reservoir = 80` foi a melhor entre as testadas. Quando o reservatório ficou pequeno demais (`40`), o erro explodiu. Mas aumentar para `120` e `160` também piorou.

Esse comportamento sugere que capacidade útil e compatibilidade com o problema importam mais do que simplesmente aumentar a dimensionalidade.

5. Estabilidade e mistura: o papel do spectral radius

O `spectral_radius` reescala a matriz recorrente para controlar o quanto a dinâmica interna amplifica ou dissipa o estado.

spectral_radius	MAE	RMSE	WAPE	sMAPE
0.2	275.280	347.305	0.1271	0.1420
0.4	340.569	454.497	0.1573	0.1764
0.6	324.294	423.417	0.1498	0.1653
0.8	871.792	1188.448	0.4026	0.6992
1.0	500.267	632.914	0.2310	0.2519

A varredura mostra três regimes didaticamente importantes:

1. `0.2` produziu o melhor conjunto de métricas entre os valores testados;
2. `0.6` ficou em uma faixa intermediária e foi o default do primeiro pipeline;
3. `0.8` e `1.0` degradaram muito a estabilidade, com explosao de erro.

Em outras palavras, este recorte prefere um reservatório mais contido do que o default inicial sugeria.

6. Como ler os hiperparametros do RC no código

O ponto de entrada do tuning esta em `RCConfig`:

```
@dataclass(frozen=True)
class RCConfig:
    n_reservoir: int = 80
    spectral_radius: float = 0.6
    leak_rate: float = 0.15
    input_scale: float = 0.8
    bias_scale: float = 0.1
    washout: int = 14
    ridge_alpha: float = 1e-3
    seed: int = 7
```

Um modo pratico de estudar o modelo e variar apenas um hiperparametro por vez, mantendo os demais fixos. Foi exatamente isso que os artefatos deste artigo fizeram.

7. O que o resultado atual do RC sugere

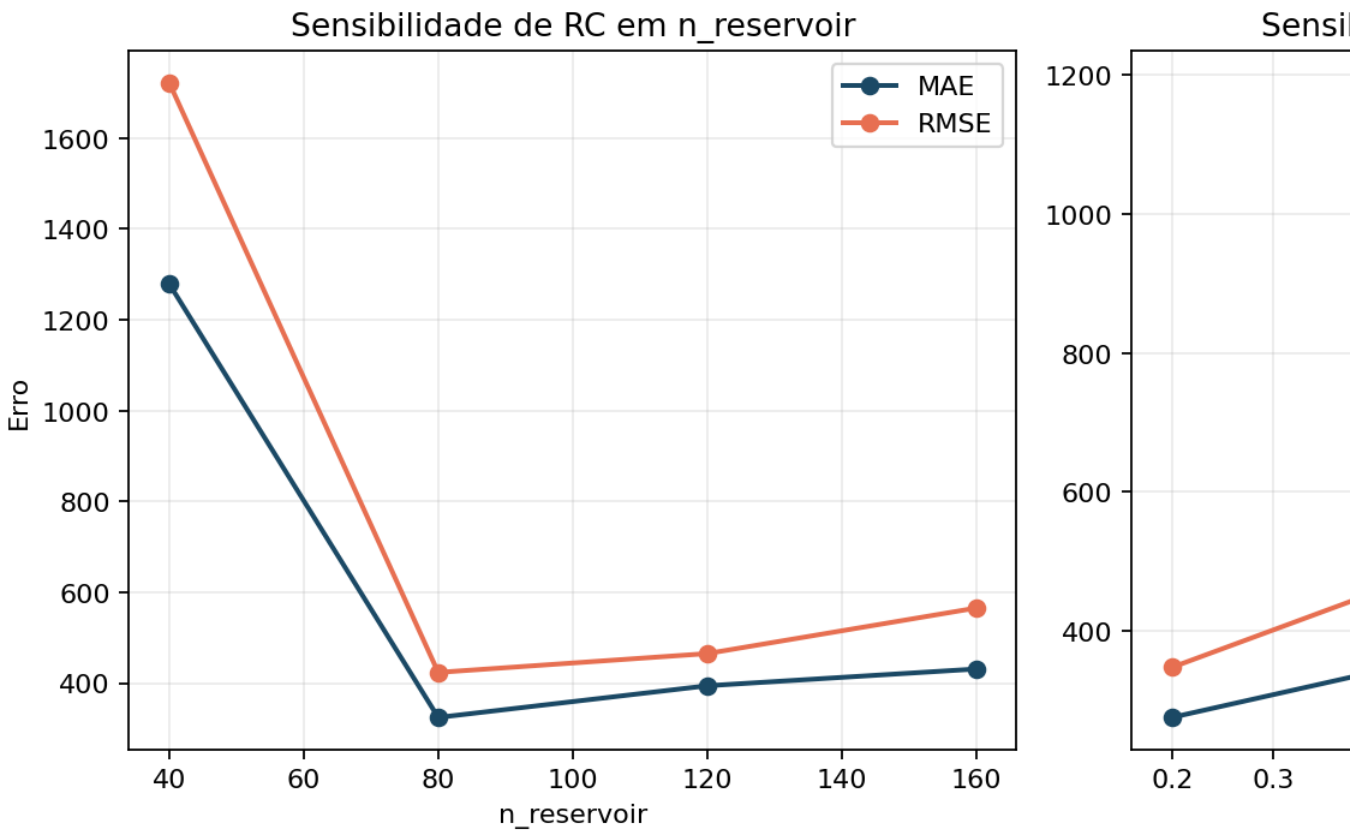

O resumo visual permite uma leitura didática direta:

- o modelo e sensivel ao `spectral_radius`;
- o `leak_rate` possui um ponto intermediário útil;
- o tamanho do reservatório tem um regime otimo local, e não monotonia.

Isso confirma uma licao central para a série: o RC não deve ser avaliado apenas por uma configuração arbitraria. Seu desempenho depende de como ajustamos memória, mistura e capacidade.

8. O que RC faz bem e o que ainda não faz bem aqui

8.1. O que RC faz bem

- constroi uma representação temporal dinâmica de baixo custo de treinamento;
- absorve sinais de promoção e calendário sem uma engenharia tabular extensa;
- oferece uma ponte conceitual excelente para o QRC.

8.2. O que RC ainda não faz bem aqui

- ainda não supera os melhores modelos clássicos neste recorte;
- ainda depende de tuning cuidadoso para evitar instabilidade ou sub-representação;
- ainda não incorpora a riqueza completa do dataset Favorita.

9. Passo-a-passo para reproduzir o estudo de sensibilidade

Um leitor que queira repetir este artigo pode seguir esta sequência:

1. executar `python code/rc/run.py` para fixar a configuração base;
2. alterar `RCConfig` em `code/rc/model.py` ou criar instancias novas em um script de experimento;
3. rerodar a previsão para cada combinacao;
4. comparar `MAE`, `RMSE`, `WAPE` e `sMAPE`;
5. guardar o resultado em CSV e imagem, como foi feito em `computational_results_20260402_222902/`.

Esse processo prepara o leitor para a fase seguinte da série, em que a comparação deixa de ser apenas "baseline versus RC"e vira um benchmark mais amplo.

10. Conclusão

Este artigo mostrou que o RC funciona porque oferece memória distribuída e não linearidade controlada, mas que essa vantagem depende de como configuramos o sistema dinamico. O proprio comportamento das varreduras do projeto ensina essa licao melhor do que qualquer definicao abstrata: parametros inadequados destroem o desempenho, enquanto escolhas razoaveis tornam o reservatório competitivo o suficiente para merecer comparação seria.

11. Entregaveis associados no repositorio

- implementação do RC: `code/rc/model.py`
- artefatos de sensibilidade: `computational_results_20260402_222902/`
- arquivos principais: `rc_sweep_n_reservoir.csv`, `rc_sweep_spectral_radius.csv`, `rc_sweep_leak_rate.csv`, `rc_sensitivity_summary.png`

12. Referências

Referências

[1] JAEGER, H. **The “echo state” approach to analysing and training recurrent neural networks**. Bonn: German National Research Center for Information Technology (GMD), 2001.

[2] LUKOSEVICIUS, M.; JAEGER, H. **Reservoir computing approaches to recurrent neural network training**. *Computer Science Review*, v. 3, n. 3, p. 127–149, 2009.

[3] LUKOSEVICIUS, M. **A practical guide to applying echo state networks**. In: MONTAVON, G.; ORR, G. B.; MÜLLER, K.-R. (org.). *Neural Networks: Tricks of the Trade*. 2. ed. Berlin: Springer, 2012. p. 659–686.

[4] FUJII, K.; NAKAJIMA, K. **Harnessing disordered-ensemble quantum dynamics for machine learning**. *Physical Review Applied*, v. 8, n. 2, 024030, 2017.