Avaliação e boas práticas

Anderson Fernandes Pereira dos Santos

Instituto Militar de Engenharia (IME), Rio de Janeiro, Brazil
Venturus Innovation Center, Campinas, Brazil
anderson@ime.eb.br | anderson.santos@venturus.org.br

Resumo. *Este artigo organiza o benchmark central da série. O objetivo não é apenas mostrar uma tabela final, mas ensinar como comparar modelos de séries temporais de forma justa quando o interesse e chegar até RC e QRC sem perder contato com técnicas clássicas fortes. Por isso, o texto formaliza o protocolo experimental, resume as implementações já construídas no projeto, apresenta as equações mínimas das famílias avaliadas e discute o benchmark consolidado real no recorte adotado no Favorita. O resultado mais importante e metodológico:* `ETS`, `XGBoost` *e* `Prophet` *formam uma referencia forte que impede avaliar RC e QRC contra baselines fracos.*

1. O que o leitor vai aprender

Ao final deste artigo, você será capaz de:

1. comparar modelos temporais com um protocolo realmente comum;
2. entender o papel de cada família de modelo no benchmark;
3. ler uma tabela comparativa sem cair em conclusoes apressadas;
4. reproduzir o benchmark com os scripts do projeto;
5. usar os resultados clássicos como referencia seria para RC e QRC.

2. Por que avaliação em séries temporais e delicada

Em séries temporais, avaliação injusta aparece facilmente:

- quando um modelo usa um split temporal diferente;
- quando features usam informação do futuro;
- quando um modelo recebe regressoras exógenas e outro não;
- quando os horizontes de previsão não coincidem;
- quando as métricas destacadas mudam de um experimento para outro.

Para evitar isso, este projeto fixa o seguinte principio:

$$\text{mesmo recorte} + \text{mesmo split} + \text{mesmas métricas} = \text{comparação honesta.}$$

3. Protocolo experimental da série

3.1. Recorte comum

Todos os modelos usam:

- `store_nbr = 1`
- `family = BEVERAGES`
- frequência diária
- últimos `90` dias como teste

3.2. Regra de split

Formalmente:

$$\mathcal{D}_{train} = \{(x_t, y_t)\}_{t=1}^{T-90}, \qquad \mathcal{D}_{test} = \{(x_t, y_t)\}_{t=T-89}^{T}.$$

3.3. Modelos avaliados

```
\begin{table}[htbp]
\centering
\small
\begin{tabularx}{\linewidth}{@{}lYY@{}}
\toprule
Modelo & Implementacao & Ideia central \\
\midrule
Seasonal Naive & \path{code/baselines/seasonal_naives/} & repete
a ultima semana observada \\
ETS & \path{code/baselines/ets/} & modelo de nivel, tendencia e
sazonalidade aditiva \\
Prophet & \path{code/baselines/prophet/} & decomposicao de
tendencia, sazonalidade e regressor exogeno \\
XGBoost & \path{code/classical/xgboost/} & aprendizado tabular
sobre lags e medias moveis \\
LSTM & \path{code/classical/lstm/} & rede recorrente treinada
por gradiente \\
RC & \path{code/rc/} & reservatorio fixo e readout linear \\
QRC & \path{code/qrc/} & reservatorio quantico implementado com
Qiskit \\
\bottomrule
\end{tabularx}
\end{table}
```

3.4. Métricas avaliadas

O benchmark usa:

$$\text{MAE, RMSE, WAPE, sMAPE.}$$

As implementações dessas métricas estao em `code/common/metrics.py`.

4. As famílias de modelo em uma pagina

Para manter a comparação didática, vale resumir a lógica de cada família.

4.1. Seasonal Naive

$$\hat{y}_t = y_{t-7}.$$

Serve como baseline sazonal mínimo.

4.2. ETS

O ETS aditivo pode ser resumido por

$$\begin{aligned} \ell_t &= \alpha(y_t - s_{t-m}) + (1-\alpha)(\ell_{t-1} + b_{t-1}), \\ b_t &= \beta(\ell_t - \ell_{t-1}) + (1-\beta)b_{t-1}, \\ s_t &= \gamma(y_t - \ell_t) + (1-\gamma)s_{t-m}. \end{aligned}$$

4.3. Prophet

O Prophet modela a série como

$$y(t) = g(t) + s(t) + h(t) + \beta x_t + \epsilon_t,$$

em que `onpromotion` entra como regressor exógeno no projeto.

4.4. XGBoost

O modelo tabular usa lags, médias móveis e calendário para aprender

$$\hat{y}_t = \sum_{m=1}^{M} f_m(z_t),$$

com z_t contendo `lag_1`, `lag_7`, `lag_14`, `lag_28`, médias móveis e calendarios.

4.5. LSTM

A LSTM usa portas para atualizar memória:

$$\begin{gathered} i_t = \sigma(W_i[h_{t-1}, x_t] + b_i), \quad f_t = \sigma(W_f[h_{t-1}, x_t] + b_f), \\ c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t. \end{gathered}$$

4.6. RC

$$x_t = (1-\alpha)x_{t-1} + \alpha \tanh(W_{res}x_{t-1} + W_{in}u_t + b).$$

4.7. QRC

O QRC será detalhado nos artigos 6 e 7, mas aqui ele entra como

$$z_t^{(j)} = \langle \psi_t | O_j | \psi_t \rangle, \qquad \hat{y}_t = W_{out}[1; u_t; z_t].$$

5. Benchmark comparativo atual

A tabela abaixo resume os resultados reais obtidos no projeto.

Modelo	Família	MAE	RMSE	WAPE	sMAPE
ETS	baseline estatístico	216.303	307.638	0.0999	0.1042
XGBoost	ML clássico	256.666	332.828	0.1185	0.1237
Prophet	baseline estatístico	257.584	321.818	0.1189	0.1319
Seasonal Naive	baseline estatístico	259.067	352.280	0.1196	0.1361
RC	reservoir computing clássico	324.294	423.417	0.1498	0.1653
LSTM	DL clássico	371.827	461.342	0.1717	0.1822
QRC14x7	reservoir computing quântico	441.286	525.325	0.2038	0.2269
QRC8x5	reservoir computing quântico	455.833	526.949	0.2105	0.2342

Uma leitura ordenada por rank médio reforca a comparação.

Modelo	Rank médio	MAE	RMSE	WAPE	sMAPE
ETS	1.00	216.303	307.638	0.0999	0.1042
XGBoost	2.25	256.666	332.828	0.1185	0.1237
Prophet	2.75	257.584	321.818	0.1189	0.1319
Seasonal Naive	4.00	259.067	352.280	0.1196	0.1361
RC	5.00	324.294	423.417	0.1498	0.1653
LSTM	6.00	371.827	461.342	0.1717	0.1822
QRC14x7	7.00	441.286	525.325	0.2038	0.2269
QRC8x5	8.00	455.833	526.949	0.2105	0.2342

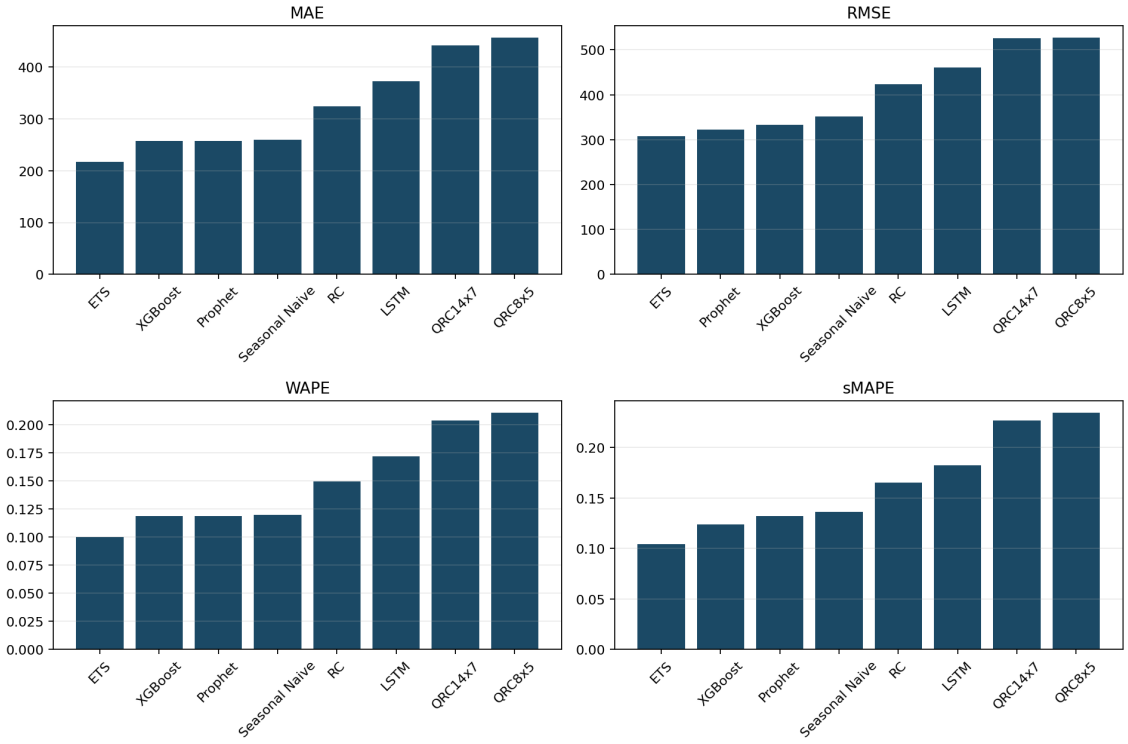

Figura 1. Comparação visual das métricas do benchmark completo.

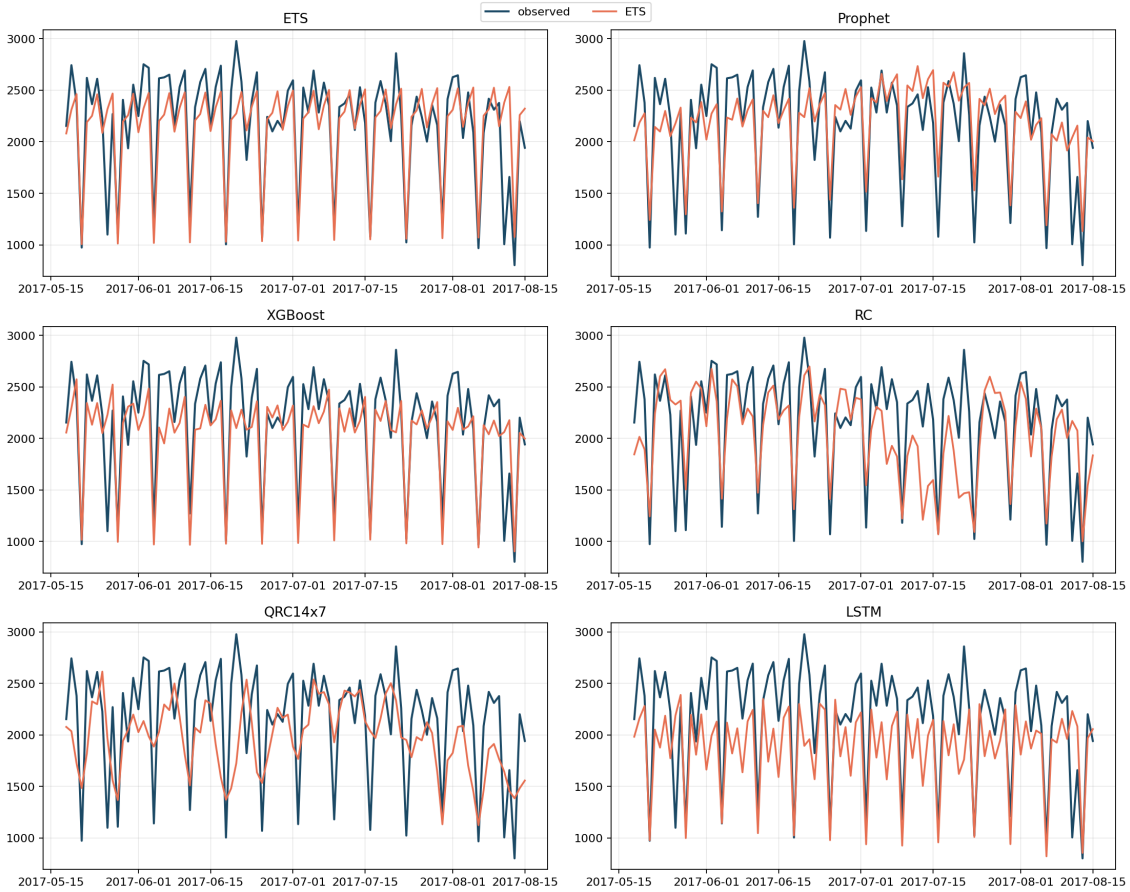

Figura 2. Grade de previsões dos diferentes modelos no mesmo bloco de teste.

6. Leitura dos resultados

6.1. ETS na lideranca

O `ETS` foi o melhor modelo no recorte em todas as métricas principais. Isso é importante porque mostra que um baseline estatístico bem implementado continua sendo uma referencia difícil de bater.

6.2. XGBoost e Prophet como faixa intermediária forte

`XGBoost` e `Prophet` formam uma segunda faixa de desempenho. Ambos ficaram muito próximos do `Seasonal Naive` em algumas métricas, mas entregaram um pacote mais robusto no conjunto do benchmark.

6.3. O que o RC entrega

O `RC` superou a `LSTM`, o que é pedagogicamente interessante. Em um setup pequeno e pouco ajustado, uma rede recorrente treinada por gradiente não vence automaticamente um reservatório fixo.

6.4. O que o QRC entrega

O `QRC` funcionou de ponta a ponta e foi comparado no mesmo recorte de dados. No entanto, ficou abaixo das técnicas clássicas neste benchmark. Isso não invalida o estudo; ao contrario, torna a comparação mais honesta.

7. O que significa uma comparação justa

Este benchmark só é didaticamente útil porque respeita três regras:

1. todos os modelos usam os mesmos dados;
2. todos produzem previsão para os mesmos `90` dias;
3. todos sao julgados pelas mesmas métricas.

Isso evita a narrativa enganosa de que um modelo "venceu"porque recebeu mais contexto ou uma tarefa mais fácil.

8. Passo-a-passo para reproduzir o benchmark

A reprodução pode ser feita em lotes, executando um script por família:

```
python code/baselines/seasonal_naives/run.py
python code/baselines/ets/run.py
python code/baselines/prophet/run.py
python code/classical/xgboost/run.py
python code/classical/lstm/run.py
python code/rc/run.py
python code/qrc/run.py
```

Os testes associados seguem a mesma organização:

```
pytest code/baselines/seasonal_naives/test_model.py
pytest code/baselines/ets/test_model.py
pytest code/baselines/prophet/test_model.py
pytest code/classical/xgboost/test_model.py
pytest code/classical/lstm/test_model.py
pytest code/rc/test_model.py
pytest code/qrc/test_model.py
pytest code/qrc/test_objective.py
```

9. Checklist de boas praticas

O artigo deixa um checklist mínimo para os próximos experimentos:

- manter o split temporal fixo;
- registrar métricas em arquivo;
- salvar previsões e figuras;
- documentar hiperparâmetros;
- não comparar RC e QRC apenas com baselines fracos.

10. Regras herdadas para a fase QRC

Quando chegarmos ao QRC, duas regras deste benchmark continuam valendo:

1. o QRC deve ser comparado com as técnicas clássicas já implementadas;
2. o mesmo recorte de dados deve ser mantido, mesmo que o reservatório quântico simplifique sua representação interna.

Isso é o que transforma o estudo final em um artigo de ensino serio, e não em uma demonstracao isolada.

11. Conclusão

O benchmark consolidado da série esta agora estabelecido. Ele mostra que a competição relevante para RC e QRC não é contra referencias artificiais, mas contra modelos clássicos fortes e bem executados. Isso torna a rota até QRC intelectualmente mais exigente, mas também muito mais valiosa.

Entregaveis associados no repositorio

- benchmark consolidado: `code/RESULTS.md`
- implementações de baseline: `code/baselines/`
- implementações clássicas: `code/classical/`
- implementação de RC: `code/rc/`
- implementação de QRC: `code/qrc/`
- artefatos comparativos deste artigo: `computational_results_20260402_222902/`

12. Referências

Referências

[1] JAEGER, H. **The "echo state" approach to analysing and training recurrent neural networks**. Bonn: German National Research Center for Information Technology (GMD), 2001.

[2] LUKOSEVICIUS, M.; JAEGER, H. **Reservoir computing approaches to recurrent neural network training**. *Computer Science Review*, v. 3, n. 3, p. 127–149, 2009.

[3] LUKOSEVICIUS, M. **A practical guide to applying echo state networks**. In: MONTAVON, G.; ORR, G. B.; MÜLLER, K.-R. (org.). *Neural Networks: Tricks of the Trade*. 2. ed. Berlin: Springer, 2012. p. 659–686.

[4] FUJII, K.; NAKAJIMA, K. **Harnessing disordered-ensemble quantum dynamics for machine learning**. *Physical Review Applied*, v. 8, n. 2, 024030, 2017.