Quantum Reservoir Computing para previsao de demanda: um estudo didatico com o Favorita

Resumo. *Este artigo fecha a serie com um estudo completo e didatico de Quantum Reservoir Computing (QRC) aplicado ao recorte do Favorita adotado desde o primeiro capitulo. O texto unifica tudo o que foi construido anteriormente: problema de negocio, protocolo experimental, benchmark justo, intuicao de reservatorio e ponte conceitual para o quantico. Em seguida, apresenta o pipeline do QRC implementado com Qiskit, compara as configuracoes* `14x7` *e* `8x5`*, discute a funcao objetivo usada no tuning e posiciona os resultados do QRC ao lado de* `ETS`*,* `XGBoost` *e* `RC`*. O resultado final e instrutivo: o QRC funciona de ponta a ponta,* `14x7` *e a melhor configuracao por desempenho puro,* `8x5` *e o melhor compromisso pela funcao objetivo, mas as tecnicas classicas seguem superiores neste recorte.*

0.1. 1. O que o leitor vai aprender

Ao final deste artigo, voce sera capaz de:

1. descrever o pipeline completo de QRC do projeto;
2. executar o modelo com Qiskit no recorte do Favorita;
3. interpretar por que `14x7` e `8x5` coexistem como candidatos fortes;
4. comparar o QRC com RC e modelos classicos no mesmo protocolo;
5. concluir o que a serie inteira ensina sobre a rota ate QRC.

0.2. 2. O recorte experimental herdado da serie

O estudo final nao muda o problema para favorecer o QRC. Ele preserva:

- `store_nbr = 1`
- `family = BEVERAGES`
- frequencia diaria
- ultimos `90` dias como teste

Isso garante continuidade didatica e comparabilidade cientifica.

0.3. 3. Pipeline de QRC usado no projeto

0.3.1. 3.1 Entrada

O QRC usa um vetor de entrada classico reduzido:

$$u_t = \begin{bmatrix} \widetilde{y}_{t-1} & \widetilde{p}_t & \sin(2\pi\,\mathrm{dow}_t/7) & \cos(2\pi\,\mathrm{dow}_t/7) \end{bmatrix}^\top .$$

Essa reducao aparece em `_quantum_input_vector()`, que seleciona os quatro primeiros componentes do vetor sequencial classico.

0.3.2. 3.2 Dinamica quantica

Para cada passo da janela, o circuito aplica rotacoes `RX` e `RY` em todos os qubits e um anel de emaranhamento `CZ` + `RZ`. Se chamarmos o operador de um passo de $U(u_t)$, a representacao da janela fica

$$|\psi_t\rangle = U(u_t)U(u_{t-1})\cdots U(u_{t-w+1})|0\cdots 0\rangle.$$

0.3.3. 3.3 Observaveis

As features quanticas sao expectativas:

$$z_t^{(j)} = \langle \psi_t | O_j | \psi_t \rangle.$$

O projeto usa observaveis `Z`, `X` e `ZZ`, totalizando `3q` componentes para `q` qubits.

0.3.4. 3.4 Readout

O readout final continua sendo simples:

$$\hat{y}_t = W_{out}[1; u_t; z_t],$$

com treinamento Ridge:

$$W_{out}^* = \arg\min_{W_{out}} \|Y - \Phi W_{out}\|_2^2 + \lambda \|W_{out}\|_2^2.$$

Em outras palavras, o QRC do projeto herda a filosofia central de RC: dinamica rica, readout simples.

0.4. 4. Implementacao passo-a-passo

O leitor pode percorrer a implementacao nesta ordem.

0.4.1. 4.1 Passo 1: definir a configuracao

```
@dataclass(frozen=True)
class QRCConfig:
    n_qubits: int = 14
    window: int = 7
    input_scale: float = 1.2
    ridge_alpha: float = 1e-1
    seed: int = 7
```

0.4.2. 4.2 Passo 2: construir o circuito por passo

O codigo central esta em `_step_circuit()` e usa `QuantumCircuit` do Qiskit.

0.4.3. 4.3 Passo 3: acumular a janela quantica

`features_from_window()` compoe sucessivos passos do circuito antes de criar o `Statevector`.

0.4.4. 4.4 Passo 4: medir observaveis

O metodo `_build_observables()` cria as listas de operadores `Z`, `X` e `ZZ`.

0.4.5. 4.5 Passo 5: ajustar o readout e prever

`fit_qrc_readout()` treina o Ridge e `forecast_qrc()` faz previsao recursiva no bloco de teste.

Para executar:

```
python code/qrc/run.py
pytest code/qrc/test_model.py
pytest code/qrc/test_objective.py
```

0.5. 5. Configuracao experimental

O tuning anterior deixou duas configuracoes principais:

- melhor configuracao por rank medio multi-metrica: `14x7`
- melhor configuracao pela funcao objetivo escalar: `8x5`

O artigo final preserva as duas porque elas respondem a perguntas diferentes:

- "qual performa melhor nas metricas?-> `14x7`
- "qual equilibra melhor desempenho e complexidade?-> `8x5`

0.6. 6. Resultados do QRC

A comparacao direta entre as duas configuracoes ficou assim:

Modelo	MAE	RMSE	WAPE	sMAPE
QRC14x7	441.286	525.325	0.2038	0.2269
QRC8x5	455.833	526.949	0.2105	0.2342

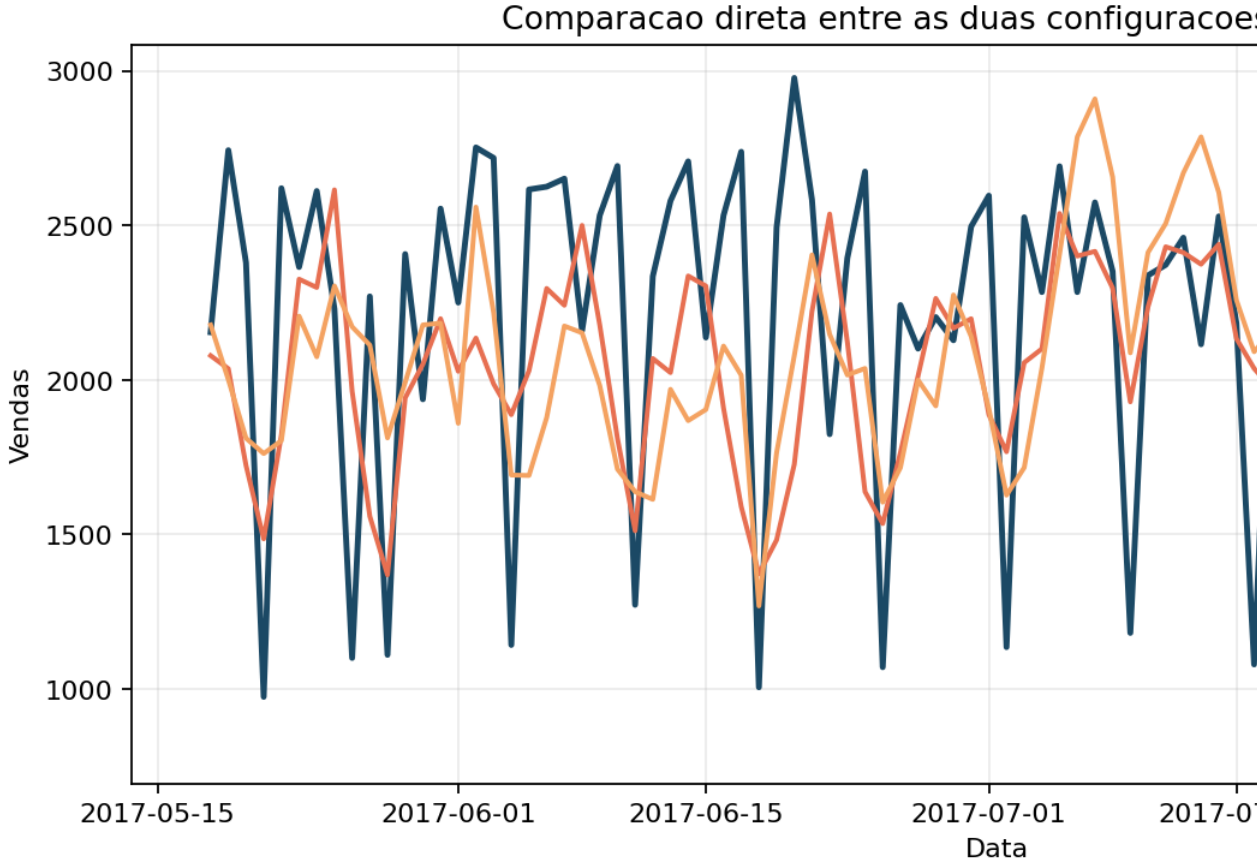
Comparacao direta entre as duas configuracoes
3000
2500
2000
1500
1000
Vendas
2017-05-15
2017-06-01
2017-06-15
2017-07-01
Data

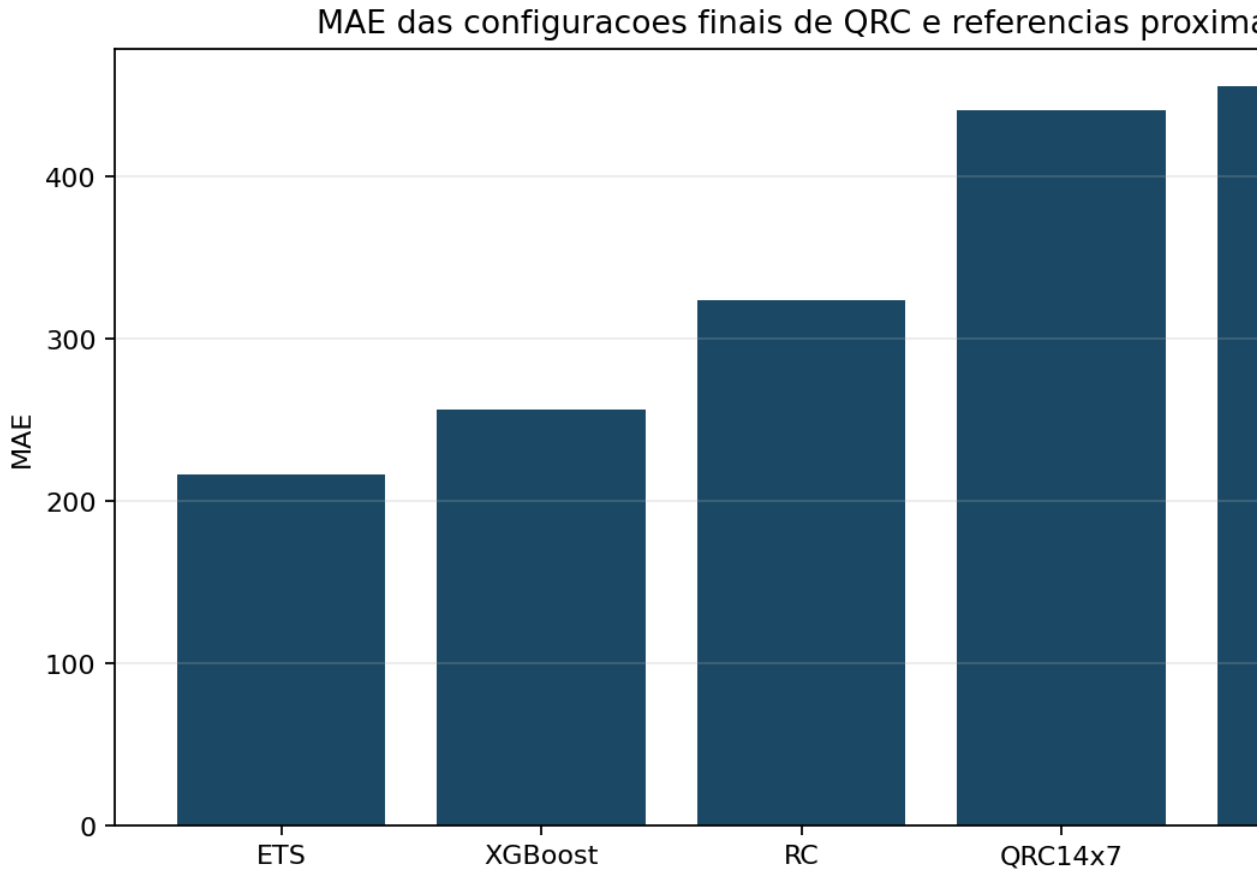

A leitura dos dois pontos e clara:

- `14x7` foi melhor que `8x5` nas quatro metricas no run direto;
- `8x5` permaneceu relevante porque sua funcao objetivo penalizada era melhor;
- o trade-off entre desempenho e complexidade foi real, nao artificial.

0.7. 7. Comparacao com RC e tecnicas classicas

O QRC precisa ser lido ao lado do benchmark herdado, nao isoladamente.

Modelo	MAE	RMSE	WAPE	sMAPE
ETS	216.303	307.638	0.0999	0.1042
XGBoost	256.666	332.828	0.1185	0.1237
RC	324.294	423.417	0.1498	0.1653
QRC14x7	441.286	525.325	0.2038	0.2269
QRC8x5	455.833	526.949	0.2105	0.2342

O ponto central do estudo e este:

- `QRC14x7` ficou cerca de 36.1% acima do `RC` em `MAE`;
- `QRC14x7` ficou cerca de 104.0% acima do `ETS` em `MAE`;
- ainda assim, o pipeline quantico funcionou de ponta a ponta no mesmo recorte de negocio.

0.8. 8. O que os resultados mostram e o que eles nao mostram

0.8.1. 8.1 O que mostram

- QRC pode ser implementado de modo didatico e reprodutivel com Qiskit;
- tuning de `qubits` e `window` importa muito;
- o melhor QRC do projeto foi `14x7`;
- comparacoes honestas sao possiveis no mesmo recorte do Favorita.

0.8.2. 8.2 O que nao mostram

- que QRC seja superior a tecnicas classicas neste problema;
- que aumentar qubits sempre melhora desempenho;
- que o estudo atual esgote o espaco de arquiteturas quanticas possiveis.

0.9. 9. A contribuicao didatica do estudo final

O estudo final nao vale apenas pela tabela de metricas. Ele vale porque fecha uma trilha de ensino completa:

1. do problema de negocio;
2. aos baselines;
3. ao RC classico;
4. ao tuning;
5. ao benchmark justo;
6. a ponte quantica;
7. ao QRC implementado e comparado.

Essa sequencia e o que transforma o conjunto dos sete artigos em um material "101"real para QRC.

0.10. 10. O que o leitor aprendeu do artigo 1 ao 7

Ao final da serie, o leitor passou a saber:

- formular um problema real de previsao de demanda;
- construir um protocolo temporal correto;
- comparar baselines, IA classica, RC e QRC;
- ler e modificar as implementacoes do projeto;
- interpretar resultados negativos ou medianos sem perder valor cientifico;
- entender QRC como extensao do paradigma de reservatorio, e nao como curiosidade isolada.

0.11. 11. Conclusao

O QRC do projeto funciona, ensina, compara e fecha a serie de forma honesta. O melhor resultado puro ficou em `14x7`; o melhor compromisso com penalizacao de complexidade ficou em `8x5`. Nenhum dos dois venceu os melhores modelos classicos no recorte do Favorita, mas ambos cumprem o papel mais importante desta obra: ensinar, de forma continua e reproduzivel, como sair do zero e chegar a um estudo completo de Quantum Reservoir Computing aplicado a um problema real.

0.12. Entregaveis associados no repositorio

- implementacao do QRC: `code/qrc/`
- tuning e funcao objetivo: `code/qrc/objective.py`, `code/qrc/OBJECTIVE.md`
- benchmark consolidado: `code/RESULTS.md`
- artefatos deste artigo: `computational_results_20260402_222902/`

0.13. Referencias

- Fujii, K.; Nakajima, K. Harnessing disordered-ensemble quantum dynamics for machine learning.
- Ghosh, S. et al. Quantum reservoir processing.
- Qiskit documentation.
- Jaeger, H. The "echo state"approach to analysing and training recurrent neural networks.
- Monzani, F.; Ricci, E.; Nigro, L.; Prati, E. QRC-Lab: An Educational Toolbox for Quantum Reservoir Computing. arXiv:2602.03522.