Quantum Reservoir Computing para previsão de demanda

Anderson Fernandes Pereira dos Santos

Instituto Militar de Engenharia (IME), Rio de Janeiro, Brazil
Venturus Innovation Center, Campinas, Brazil
anderson@ime.eb.br | anderson.santos@venturus.org.br

Resumo. *Este artigo fecha a série com um estudo completo e didático de Quantum Reservoir Computing (QRC) aplicado ao recorte adotado no Favorita desde o primeiro capítulo. O texto unifica tudo o que foi construído anteriormente: problema de negócio, protocolo experimental, benchmark justo, intuição de reservatório e ponte conceitual para o quântico. Em seguida, apresenta o pipeline do QRC implementado com Qiskit, compara as configurações* `14x7` *e* `8x5`*, discute a função objetivo usada no tuning e posiciona os resultados do QRC ao lado de* `ETS`*,* `XGBoost` *e* `RC`*. O resultado final é instrutivo: o QRC funciona de ponta a ponta,* `14x7` *e a melhor configuração por desempenho puro,* `8x5` *e o melhor compromisso pela função objetivo, mas as técnicas clássicas seguem superiores neste recorte.*

1. O que o leitor vai aprender

Ao final deste artigo, você será capaz de:

1. descrever o pipeline completo de QRC do projeto;
2. executar o modelo com Qiskit no recorte adotado no Favorita;
3. interpretar por que `14x7` e `8x5` coexistem como candidatos fortes;
4. comparar o QRC com RC e modelos clássicos no mesmo protocolo;
5. concluir o que a série inteira ensina sobre a rota até QRC.

2. O recorte experimental herdado da série

O estudo final não muda o problema para favorecer o QRC. Ele preserva:

- `store_nbr = 1`
- `family = BEVERAGES`
- frequência diária
- últimos `90` dias como teste

Isso garante continuidade didática e comparabilidade científica.

3. Pipeline de QRC usado no projeto

3.1. Entrada

O QRC usa um vetor de entrada clássico reduzido:

$$u_t = \begin{bmatrix} \widetilde{y}_{t-1} & \widetilde{p}_t & \sin(2\pi\,\mathrm{dow}_t/7) & \cos(2\pi\,\mathrm{dow}_t/7) \end{bmatrix}^\top .$$

Essa reducao aparece em `_quantum_input_vector()`, que seleciona os quatro primeiros componentes do vetor sequencial clássico.

3.2. Dinâmica quântica

Para cada passo da janela, o circuito aplica rotações `RX` e `RY` em todos os qubits e um anel de emaranhamento `CZ` + `RZ`. Se chamarmos o operador de um passo de $U(u_t)$, a representação da janela fica

$$|\psi_t\rangle = U(u_t)U(u_{t-1})\cdots U(u_{t-w+1})|0\cdots 0\rangle.$$

3.3. Observáveis

As features quânticas sao expectativas:

$$z_t^{(j)} = \langle \psi_t | O_j | \psi_t \rangle.$$

O projeto usa observáveis `Z`, `X` e `ZZ`, totalizando `3q` componentes para `q` qubits.

3.4. Readout

O readout final continua sendo simples:

$$\hat{y}_t = W_{out}[1; u_t; z_t],$$

com treinamento Ridge:

$$W_{out}^* = \arg\min_{W_{out}} \|Y - \Phi W_{out}\|_2^2 + \lambda \|W_{out}\|_2^2.$$

Em outras palavras, o QRC do projeto herda a filosofia central de RC: dinâmica rica, readout simples.

4. Implementação passo-a-passo

O leitor pode percorrer a implementação nesta ordem.

4.1. Passo 1: definir a configuração

```
@dataclass(frozen=True)
class QRCConfig:
    n_qubits: int = 14
    window: int = 7
    input_scale: float = 1.2
    ridge_alpha: float = 1e-1
    seed: int = 7
```

4.2. Passo 2: construir o circuito por passo

O código central esta em `_step_circuit()` e usa `QuantumCircuit` do Qiskit.

4.3. Passo 3: acumular a janela quântica

`features_from_window()` compoe sucessivos passos do circuito antes de criar o `Statevector`.

4.4. Passo 4: medir observáveis

O método `_build_observables()` cria as listas de operadores `Z`, `X` e `ZZ`.

4.5. Passo 5: ajustar o readout e prever

`fit_qrc_readout()` treina o Ridge e `forecast_qrc()` faz previsão recursiva no bloco de teste.

Para executar:

```
python code/qrc/run.py
pytest code/qrc/test_model.py
pytest code/qrc/test_objective.py
```

5. Configuração experimental

O tuning anterior deixou duas configurações principais:

- melhor configuração por rank médio multi-métrica: `14x7`
- melhor configuração pela função objetivo escalar: `8x5`

O artigo final preserva as duas porque elas respondem a perguntas diferentes:

- "qual performa melhor nas métricas?-> `14x7`
- "qual equilibra melhor desempenho e complexidade?-> `8x5`

6. Resultados do QRC

A comparação direta entre as duas configurações ficou assim:

Modelo	MAE	RMSE	WAPE	sMAPE
QRC14x7	441.286	525.325	0.2038	0.2269
QRC8x5	455.833	526.949	0.2105	0.2342

A leitura dos dois pontos é clara:

- `14x7` foi melhor que `8x5` nas quatro métricas no run direto;
- `8x5` permaneceu relevante porque sua função objetivo penalizada era melhor;
- o trade-off entre desempenho e complexidade foi real, não artificial.

7. Comparação com RC e técnicas clássicas

O QRC precisa ser lido ao lado do benchmark herdado, não isoladamente.

Modelo	MAE	RMSE	WAPE	sMAPE
ETS	216.303	307.638	0.0999	0.1042
XGBoost	256.666	332.828	0.1185	0.1237
RC	324.294	423.417	0.1498	0.1653
QRC14x7	441.286	525.325	0.2038	0.2269
QRC8x5	455.833	526.949	0.2105	0.2342

Modelo	MAE	RMSE	WAPE	sMAPE

O ponto central do estudo e este:

- `QRC14x7` ficou cerca de 36.1% acima do `RC` em `MAE`;
- `QRC14x7` ficou cerca de 104.0% acima do `ETS` em `MAE`;
- ainda assim, o pipeline quântico funcionou de ponta a ponta no mesmo recorte de negócio.

8. O que os resultados mostram e o que eles não mostram

8.1. O que mostram

- QRC pode ser implementado de modo didático e reprodutível com Qiskit;
- tuning de `qubits` e `window` importa muito;
- o melhor QRC do projeto foi `14x7`;
- comparações honestas sao possíveis no mesmo recorte adotado no Favorita.

8.2. O que não mostram

- que QRC seja superior a técnicas clássicas neste problema;
- que aumentar qubits sempre melhora desempenho;
- que o estudo atual esgote o espaco de arquiteturas quânticas possíveis.

9. A contribuição didática do estudo final

O estudo final não vale apenas pela tabela de métricas. Ele vale porque fecha uma trilha de ensino completa:

1. do problema de negócio;
2. aos baselines;
3. ao RC clássico;
4. ao tuning;
5. ao benchmark justo;
6. a ponte quântica;
7. ao QRC implementado e comparado.

Essa sequência e o que transforma o conjunto dos sete artigos em um material "101"real para QRC.

10. O que o leitor aprendeu do artigo 1 ao 7

Ao final da série, o leitor passou a saber:

- formular um problema real de previsão de demanda;
- construir um protocolo temporal correto;
- comparar baselines, IA clássica, RC e QRC;
- ler e modificar as implementações do projeto;
- interpretar resultados negativos ou medianos sem perder valor científico;
- entender QRC como extensão do paradigma de reservatório, e não como curiosidade isolada.

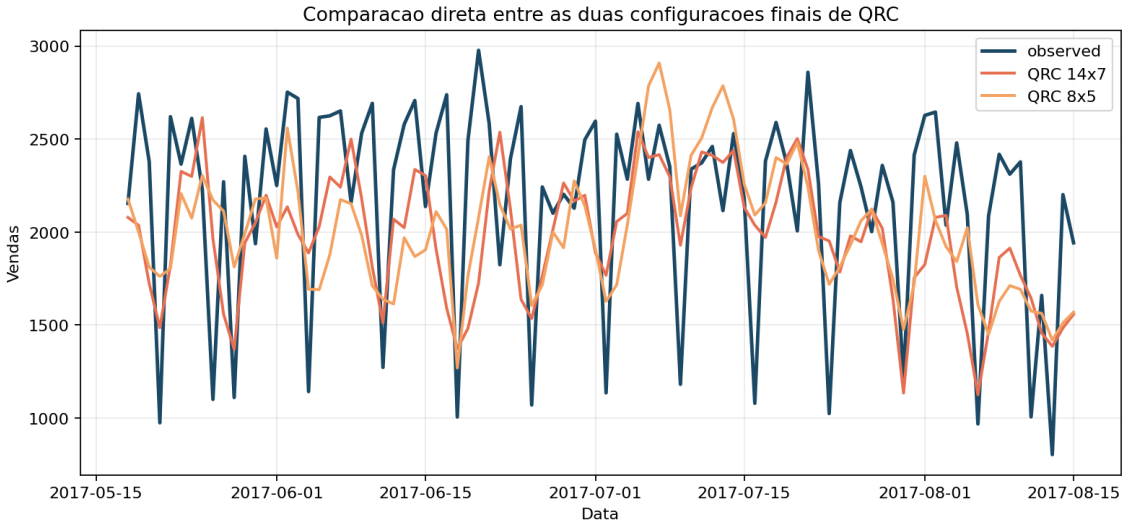

Figura 1. Comparação direta entre as configurações QRC14x7 e QRC8x5.

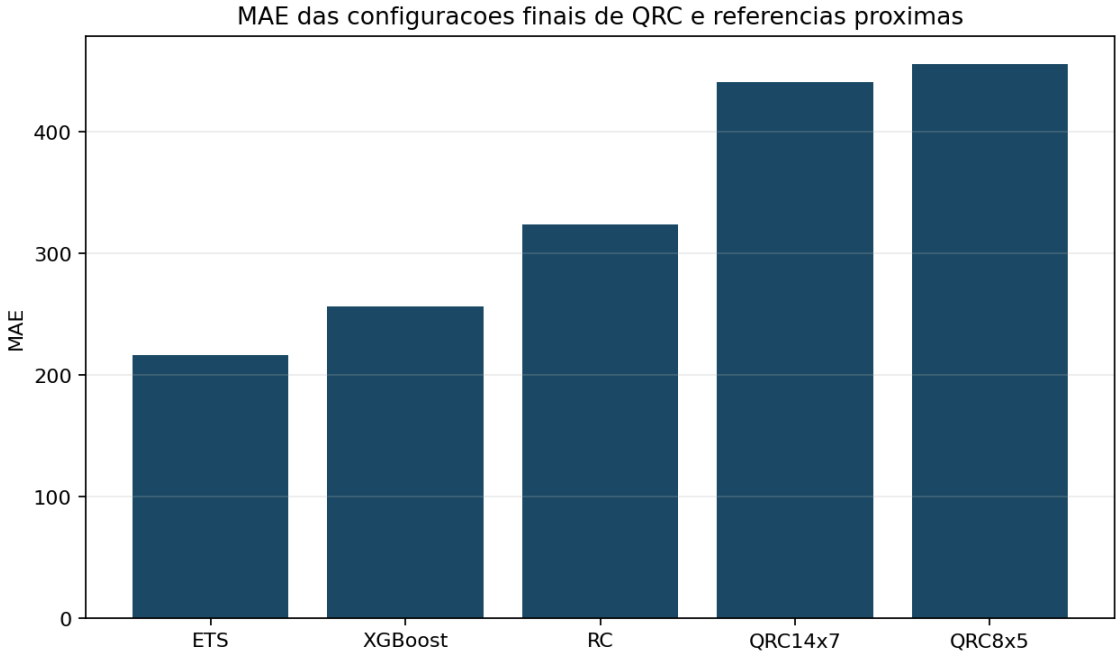

Figura 2. Comparação em barras para o MAE entre modelos de referencia e QRC.

11. Conclusão

O QRC do projeto funciona, ensina, compara e fecha a série de forma honesta. O melhor resultado puro ficou em `14x7`; o melhor compromisso com penalizacao de complexidade ficou em `8x5`. Nenhum dos dois venceu os melhores modelos clássicos no recorte adotado no Favorita, mas ambos cumprem o papel mais importante desta obra: ensinar, de forma continua e reproduzível, como sair do zero e chegar a um estudo completo de Quantum Reservoir Computing aplicado a um problema real.

Entregaveis associados no repositorio

- implementação do QRC: `code/qrc/`
- tuning e função objetivo: `code/qrc/objective.py`, `code/qrc/OBJECTIVE.md`
- benchmark consolidado: `code/RESULTS.md`
- artefatos deste artigo: `computational_results_20260402_222902/`

12. Referências

Referências

[1] JAEGER, H. **The "echo state" approach to analysing and training recurrent neural networks**. Bonn: German National Research Center for Information Technology (GMD), 2001.

[2] LUKOSEVICIUS, M.; JAEGER, H. **Reservoir computing approaches to recurrent neural network training**. *Computer Science Review*, v. 3, n. 3, p. 127–149, 2009.

[3] LUKOSEVICIUS, M. **A practical guide to applying echo state networks**. In: MONTAVON, G.; ORR, G. B.; MÜLLER, K.-R. (org.). *Neural Networks: Tricks of the Trade*. 2. ed. Berlin: Springer, 2012. p. 659–686.

[4] FUJII, K.; NAKAJIMA, K. **Harnessing disordered-ensemble quantum dynamics for machine learning**. *Physical Review Applied*, v. 8, n. 2, 024030, 2017.